1. 基本生物信息学

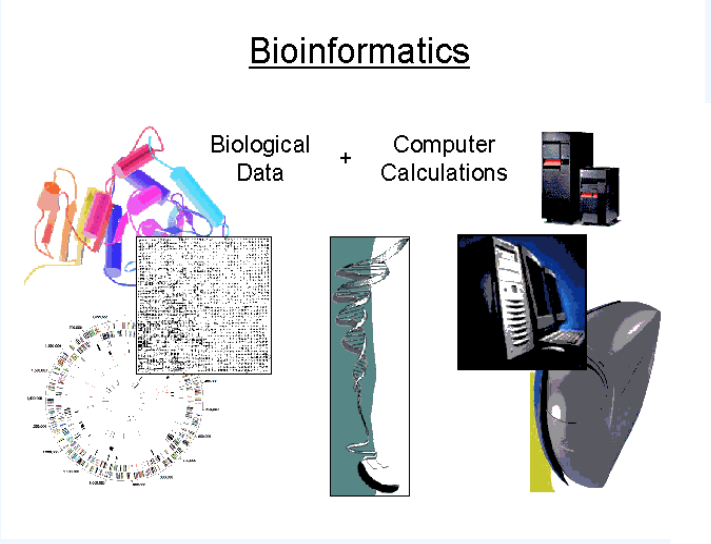
2. 三维结构数据库（PDB）

3. 三维结构可视化： Pymol

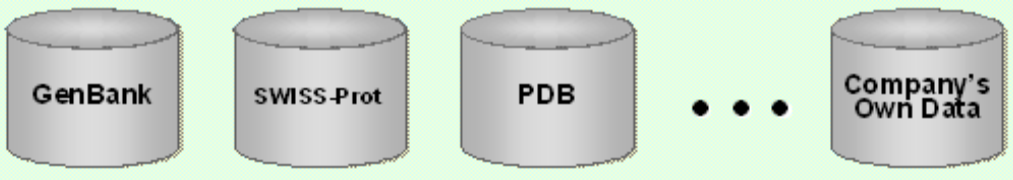
2024-10-25

基本生物信息学

1. 重要生物信息中心
2. 重要生物信息数据库
3. 数据库检索工具及分析









一、重要生物信息中心 Bioinformatics Centres

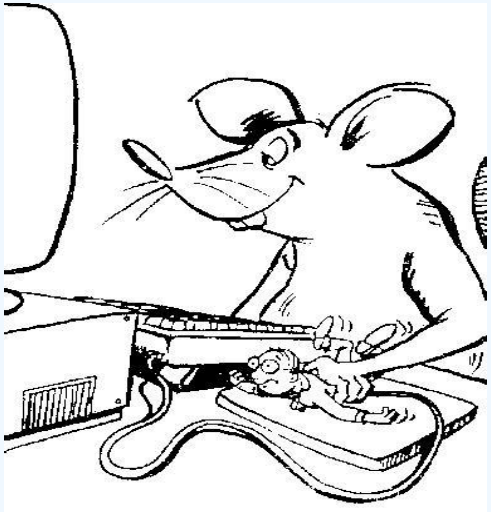
NCBI National Center for Biotechnology Information (US)

EBI European Bioinformatics Institute (EU)

DDBJ DNA Data Bank of Japan (JP)

ExPASy Expert of Protein Analysis System (Switzerland)

PDB Protein Data Bank (world-wide)



我国生物信息相关网站

- 中国生物信息网

http://www.biosino.org

- 国家南方基因研究中心

http://chgc.sh.cn/ch/

- 北京大学生物信息中心

http://www.cbi.pku.edu.cn

- 中国生物技术信息网

http://www.biotech.org.cn/

中国科学院（上海文献中心）

http://www.cshq.ac.cn,http://www.lifescience.org.cn/tushug/

生物信息学数据库种类 annual updates:

- 《Nucleic Acids Research》杂志每年的第一期中详细介绍最新版本的各种数据库。
- 在2000年1月1日出版的28卷第一期115种通用和专用数据库。
- 至2009年，生物信息学数据库总数已达1170个。

Entrez Databases

http://www.ncbi.nlm.nih.gov/Entrez/

Entrez
search and retrieval system

NCBI

National Center for Biotechnology Information

National Library of Medicine National Institutes of Health

PubMed | All Databases | BLAST | OMIM | Books | TaxBrowser | Structure

Search All Databases for Go

SITE MAP
Alphabetical List
Resource Guide

About NCBI
An introduction to NCBI

GenBank
Sequence submission support and software

Literature databases
PubMed, OMIM, Books, and PubMed Central

Molecular databases
Sequences, structures, and taxonomy

Genomic biology
The human

What does NCBI do?

Established in 1988 as a national resource for molecular biology information, NCBI creates public databases, conducts research in computational biology, develops software tools for analyzing genome data, and disseminates biomedical information - all for the better understanding of molecular processes affecting human health and disease. More...

My NCBI The new My NCBI has replaced the Cubby and includes automatic e-mailing of search updates and filtering search results. A tab format is used for features such as Limits and displaying filtered search results.

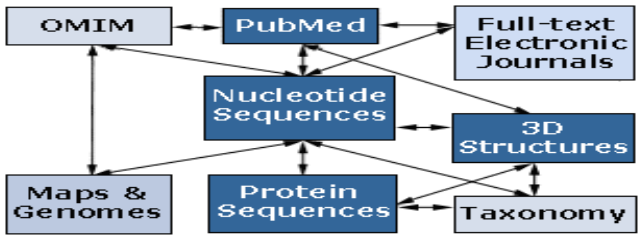
Entrez Gene

You can now use Entrez to search for information centered on the concept of a gene, and connect to many sources of related information both within and outside NCBI.

Hot Spots

- Assembly Archive
- Clusters of orthologous groups
- Coffee Break, Genes & Disease, NCBI Handbook
- Electronic PCR
- Entrez Home
- Entrez Tools
- Gene expression omnibus (GEO)
- Human genome resources
- Malaria genetics & genomics
- Map Viewer

Entrez is a search and retrieval system that integrates information from databases at NCBI. These databases include nucleotide sequences, protein sequences, macromolecular structures, whole genomes, and MEDLINE, through PubMed.



European Bioinformatics Institute

http://www.ebi.ac.uk/

Database Search for [ ] in [Nucleotide sequences] Go Search EBI Website [ ] Go



European Bioinformatics Institute

Research at the European Bioinformatics Institute

Bioinformatics Products and Services

FLASH Intro

European Bioinformatics Institute
a part of the European Molecular Biology Laboratory

the path to knowledge

About EBI | Funding | Whats New | Research Groups | Services | Toolbox | EBI Databases | Downloads | Submissions
BioMart Database Queries | SRS Database Queries | Site Search | Site Map | Services Map | PhD Studies | Contact Us | Terms of Use

2can Bioinformatics - Training and Education at the EBI

© Copyright European Bioinformatics Institute 2002-2004. All Rights and Trademarks Reserved.

Internet

DNA Database of Japan

http://www.ddbj.nig.ac.jp/



Japanese Page

Search DDBJ Site for Go

Site Map

about DDBJ

Data Submission

SAKURA
Data Updates
Mass Submission

Search & Analysis

SRS getentry
ARSA NEW
FASTA BLAST
S&W SEARCH
SQmatch XML
TXSearch GIB
ClustalW
GTOP LIBRA

Download data

about DDBJ

DDBJ (DNA Data Bank of Japan) began DNA data bank activities in earnest in 1986 at the National Institute of Genetics (NIG).
DDBJ has been functioning as the international nucleotide sequence database in collaboration with EBI/EMBL and NCBI/GenBank.
DNA sequence records organismic evolution more directly than other biological materials and thus is invaluable not only for research in life sciences but also human welfare in general. The databases are, so to speak, a common treasure of human beings. With this in mind, we make the databases online accessible to anyone in the world.

DNA Data Bank of Japan (DDBJ)
Center for Information Biology and DNA Data Bank of Japan (CIB-DDBJ)
National Institute of Genetics (NIG) | SOKENDAI, Department of Genetics
Research Organization of Information and Systems

DDBJ uses the Super SINET computer network for its business.

♦What's new

- modified: Mar.11

♦Hot Topics

- Integration of ClustalW and ClustalW DDBJ version (Mar.07) NEW
- Incomplete ftp from UniProt (SwissProt) in February (Mar.04) NEW
- Preliminary notice for the termination of S&W SEARCH sercice(Feb.18) NEW
- Release of a large amount of transcript sequences in new category MGA (Jan.24)
- Finished Human Genome Sequence was published (Nov.5,2004)

♦Announcement

- CON entries revision due to the removal of sequence length limita tion (Oct.26,2004)

Internet

ExPASy Server

http://www.expasy.ch/

Site Map



SWISS-MODEL

An Automated Comparative Protein Modelling Server

Introduction:

SWISS-MODEL is an Automated Protein Modelling Server developped at the GlaxoSmithKline in Geneva, Switzerland.

The purpose of this server is to make Protein Modelling accessible to all biochemists and molecular biologists World Wide.

The present version of the server is 3.5 and is under constant improvement and debugging. In order to help us refine the sequence analysis and modelling algorithms, please report of possible bugs and problems with the modelling procedure.

Protein Data Bank (Structures)

http://www.rcsb.org/pdb/

PDB PROTEIN DATA BANK

PDB PROTEIN DATA BANK

Structure Explorer - 1GDI



Summary Information

- Summary Information
- View Structure
- Download / Display File
- Structural Neighbors
- Geometry
- Other Sources
- Sequence Details

Explore SearchLite SearchFields

Title: The binding of carbon monoxide and nitric oxide to leghaemoglobin in comparison with other haemoglobins.
Compound: Leghemoglobin (Carbon Monoxy)
Authors: E. Harutyunyan, T. Safonova, I. Kuranova
Exp. Method: X-ray Diffraction
Classification: Oxygen Transport
Source: not available
Primary Citation:

Deposition Date: 14-Sep-1994 *Release Date:* 27-Feb-1995

Resolution [Å]: 1.80 *R-Value:* 0.183
Space Group: C 2
Unit Cell: *dim [Å]:* *a* 93.19 *b* 51.95 *c* 38.30
angles [°]: *alpha* 90.00 *beta* 98.80 *gamma* 90.00

Polymer Chains: 1GDI *Residues:* 153
Atoms: 1375
HET groups:

ID	Name	Formula
CMO	CARBON MONOXIDE	CO
HEM	PROTOPORPHYRIN IX CONTAINING FE	$C_{34}H_{32}N_4O_4Fe$

CBI Center of Bioinformatics 北京大学生物信息中心 English Version

National node of EMBnet

主页 | SRS | BLAST | 最新消息 | 镜像站点 | 在线教程 | 关于CBI | 招生信息

2006年03月09日

国外站点

- NCBI
- EBI
- APBionet

More>>

国内站点

- 上海生物信息中心
- 华大基因组信息中心
- 天大生物信息中心
- 计算所生物信息中心
- 复旦理论生物中心

More>> new!

友情链接

- 国家教育科研网
- 国家学术文献系统
- 教育部网上合作中心
- 北京大学
- 北大图书馆
- 北大耶鲁合作中心

搜索引擎

- Google

最新消息

学术报告：基因起源：速度和模式(28 Feb,2006)
会议通知：中国国际分子医学与生物技术会议(2005-10-17)
会议通知：International Bioinformatics Workshop (IBW 2005)
会议通知：ISMB 2005, (June, 2005)

more>>

R&D

CBIRD-（CBI Reasch and Development）包括PAK（蛋白质组注释系统）、SPD（分泌蛋白数据库）、 DATF（拟南芥转录因子数据库）、Bioland等由北京大学生物信息中心构建和维护的生物信息学数据库及研究平台。 new!

SRS

SRS（Sequence Retrieval System）是由欧洲生物信息研究所（EBI）开发的以WWW界面运行的数据库检索及导航系统， 是目前生物信息界应用最为广泛的数据库系统。CBI目前已经可以提供超过100种数据库的搜索，其中 比较常用的EMBL和GDB等已做到每日更新。

BLAST

BLAST（Basic Local Alignment System），数据库查询工具，是最常用的比较核酸和蛋白质同源性比较工具，本中心采用的是NCBI的BLAST2.0网络版。可以直接通过网页提交查询。如果网速不够快的话，还可以选择用E-mail接收BLAST结果。

Mirrors

本站建立了多个世界著名生物信息网站的镜像，从而使得教育网用户可以节省很多时间和费用就可以使用这些优秀的网站资源。大多数的镜像已经完全实现本地化，但是不排除会有少数的链接指向源站点。这些站点包括GDB、EXPASY、TransFac和MEDLINE等等。

BioSino 中国生物信息

Assays-on-Demand
分析试剂盒

新闻导读

- 禽流感专题 NEW
- 非典专题（SARS） NEW
- 生物科学界再爆丑闻 克隆羊之
- 日美专家发现能抑制骨质疏松化
- 美卫生官员称必须研制针对禽流
- 美人类干细胞研究项目惹法律纠
- 可生物降解微球应用于蛋白类药

[更多...]

焦 点 新 闻 [每天更新]

生物学界再爆丑闻 克隆羊之父承认剽窃



新浪科技讯 据《每日电讯报》8日报道，继韩国著名科学家黄禹锡造假丑闻曝光后，有克隆羊“多利”缔造者之称的苏格兰籍科学家伊恩·维尔莫特7日也承认，“多利”并不是由他克隆的。克隆羊“多利”的诞生当时轰动了整个世界，这一成果还名列美国《科学》杂志评选出的该年度世界十大科技进步的榜首位置。

维尔莫特在爱丁堡举行的一个听证会上表示，他在克隆羊项目中发挥了监督的角角色，作用并非“微不足道”。但是，维尔莫特确实没有发展这项技术或从事一项突破性实验，这次实验最终令科学家成功从单个细胞中首次克隆出成年动物。维尔莫特承认，按照与同事基思·坎贝尔博士达成的协议，他才作为描述克隆羊“多利”诞生论文的主要作者出现。

2005.3.8 [看个仔细...]

DNA 50周年纪念 NEW

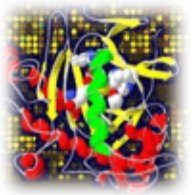
James Watson and Francis Crick unveiled their model for the structure of DNA in the journal Nature fifty years ago this week. To celebrate, we looks back....

[更多 ...]

相关站点

- 中国科学院
- 中华人民共和国科学技术部
- 863--国家高技术研究发展计划
- 中科院上海生命科学研究院
- 北京大学生物信息学中心
- 国家人类基因组南方研究中心
- 中科院遗传与发育生物学研究所

生物信息学专题 [每周更新]



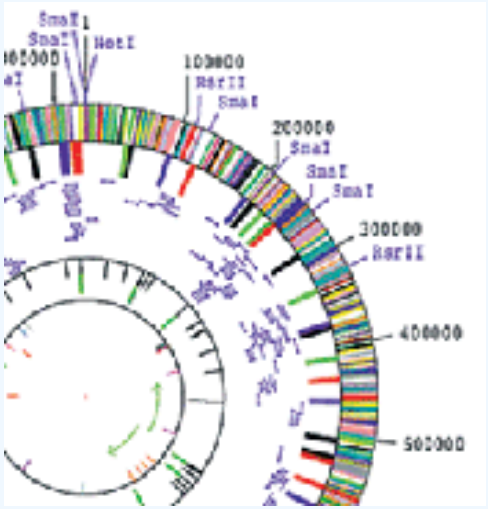
- Direct Coupling of Transcripti
- A generic motif discovery algo
- LOCATE a mouse protein subcell
- Intrinsic dynamics of an enzym
- Structural Basis for DNA Recog

LIMS最新进展 NEW

LIMS即“实验室信息管理系统”Laboratory Information Management Systems”的缩写。LIMS将实验室的分析仪器通过...

[更多 ...]

二、重要生物信息数据库


SmaI
NotI
100000
NarI
SmaI
200000
SmaI
SmaI
SmaI
300000
NarI
400000
500000


A A
C C
C C
T A
G G
A A
G G



生物数据库及其主要分类

1 核酸序列数据库
2. RNA 序列数据库
3. 蛋白质序列数据库
4. 三维结构数据库
5. 基因组数据库（非脊椎动物）
6. 代谢酶相关产物
7. 人类和其他脊椎动物基因组
8. 人类基因和疾病
9. 其他数据和其他基因表达数据库
10. 蛋白组资源
11. 其他分子生物学数据库
12. 细胞器官数据库
13. 植物数据库
14. 免疫学数据库

主要相关生物数据库

序列数据库

- 核酸序列数据库 (EMBL、GenBank、DDBJ)
- 常用蛋白质序列数据库(Swissprot,PIR)

结构数据库

- 蛋白质结构数据库(PDB)
- 蛋白质分类数据库(SCOP、CATH)

其它数据库

核酸序列数据库

- 美国的核酸数据库GenBank〖Banson,D.A. et al. (1998) Nucleic Acids Res. 26, 1-7〗从1979年开始建设，1982年正式运行；
- 欧洲分子生物学实验室的EMBL数据库也于1982年开始服务
- 日本于1984年开始建立国家级的核酸数据库DDBJ，并于1987年正式服务。

从那个时候以来，DNA序列的数据已经从80年代初期的百把条序列，几十万碱基上升至现在的110亿碱基！这就是说，在短短的约18年间，数据量增长了近十万倍。

蛋白质序列数据库

- SWISS-PROT和PIR是国际上二个主要的蛋白质序列数据库，目前这二个数据库在EMBL和GenBank数据库上均建立了镜像(mirror) 站点。SWISS-PROT数据库包括了从EMBL翻译而来的蛋白质序列，这些序列经过检验和注释。PIR数据库的数据由美国家生物技术信息中心(NCBI)翻译自GenBank的DNA序列。
- Uniprot: https://www.uniprot.org

蛋白质数据库种类和特点

名称	维护单位	注释	冗余度	数据量	更新
PIR	NCBI、JIPID、MIPS	部分完善	较大	较大	较慢
SwissProt	EBI、SIB	完善	小	不大	较慢
NRL3D	NCBI	完善	小	小	较慢
TrEMBL	EBI、SIB	不完善	大	大	快
GenPept	NCBI	不完善	大	大	快
NRDB	EBI	一般	小	大	较快
OWL	HGMP	一般	小	大	较慢

基因组数据库图谱和显示器

- 主要内容：有基因组结构、基因单位、基因组图谱等（遗传图、叠连群图、放射杂交图等）
- 分布：由各国基因组研究中心组建，分布在世界各地的信息中心、研究机构。代表性的有：
- 美国人类基因组数据库GDB
- http://www.gdb.org
- 美国NCBI基因组数据库Genomes
  http://www.ncbi.nlm.nih.gov
- 英国人类基因图谱数据库 HGMPGenomeWeb
- http://www.hgmp.mrc.ac.uk/genomeWeb/
- 美国人类基因组资源整合体系
  http://www.ncbi.nlm.nih.gov/genome/guide/human/

人类疾病与基因数据库

- OMIM 孟德尔遗传信息数据库
- http://www.ncbi.nlm.nih.gov
- CGAP The Cancer Genome Anatomy Project 肿瘤基因组图谱知识库 http://www.ncbi.nlm.nih.gov/ncicgap 美国国立癌症研究所为解剖肿瘤细胞分子而建立。

生物信息学相关分析工具

- BLAST 序列相似性对比
- PRIMER 引物设计
- 蛋白质结构预测数据库 （EMBL）根据已知蛋白质序列，预测同族二级、三维等结构
- 蛋白质功能预测数据库 （EMBL ）根据已知蛋白质序列，预测蛋白质功能

序列对比的概念

- 在生物信息学研究中，最常用和最经典的一个研究手段，就是通过比较分析获得有用的信息和知识。将研究对象进行相互比较来寻找研究对象可能具备的某些特性。从核酸及蛋白质的一级结构方面来分析序列的相同点和不同点，从而能够推测它们的结构、功能及进化上的联系。
- 序列对比的理论基础是进化学说。如果两个基因和蛋白质序列之间具有足够的相似性，就推测两者可能有共同的进化祖先，经过序列内残基的替换、缺失以及序列重组等遗传变异过程分别演化而来。
- 序列的相似性（**similarity**）：在序列对比中描述两条序列之间相同碱基或氨基酸残基所占比例。
- 序列的同源性（**homology**）：从大量数据中推断出的两个基因在进化上具有共同祖先的结论。

序列两两对比

- 描述序列两两对比通常用打分矩阵的方法。即两条序列分别作为矩阵的两维，矩阵点是两维上对应两个序列的相似性分数，分数越高则说明两个序列越相似。
- 序列对比问题即是在矩阵中寻找最佳的对比路径。
- 方法：**Needleman-Wunsch**动态规划算法；**Smith-Waterman**算法；**SIM**算法。
- 工具：**LALIGN**；**Align**、**B12Seq**等。

多序列对比

- 多序列对比是把两条以上可能有系统进化关系的序列进行对比的方法。
- 目前，使用最广泛的多序列对比程序是**CLUSTALX**。它先将多个序列进行两两对比构建距离矩阵，确立序列间的两两关系。然后根据距离矩阵计算产生系统进化指导树，对关系密切的序列进行加权。再从相似程度最高的两条序列开始，逐步引入临近的序列并不断重新构建对比，直到所有序列都被加入为止。

数据库搜索的概念

- 数据库搜索：通过序列相似性对比的算法，在核酸序列数据库和蛋白质序列数据库中检索出与被检序列具有一定相似性的序列。
- 数据库搜索的基础是序列的相似性对比。
- 被检测的序列与一个已知基因家族之间的进化关系被确定之后，通过数据库搜索可以得到一些相似序列，但它们之间的相似性程度具有差别，因此，还需要判断其序列相似性程度。（其他的研究方法和/或实验手段来验证）

数据库搜索的工具

- 虽然各种搜索程序和算法各不相同，但数据库搜索检出的结果基本相似，均采用统计学评分，并按照相似程度排序。
- 目前，应用较广泛的序列相似性搜索工具：FASTA、BLAST和BLITZ等。
- 对于DNA序列相似性检索，FASTA的敏感度较高，但BLAST检索速度较快。
- BLAST是目前应用最广泛的序列相似性搜索工具，比FASTA改进更多，搜索速度更快，并建立在严格的统计学基础之上。

BLAST程序

程序	数据库	简述
Blastp	蛋白质	可能找到具有远源进化关系的匹配序列
Blastn	核苷酸	适合寻找分值较高的匹配，不适合远源关系
Blastx	蛋白质	适合新**DNA**序列和**EST**序列的分析，能够发现未知核酸序列潜在的翻译产物
Tblastn	所有阅读框动态翻译的核苷酸序列	适合寻找数据库中尚未标注的编码区
Tblastx	核苷酸序列**6**个阅读框的翻译产物	适合表达序列标签（**EST**）分析

蛋白质三维结构数据库

- PDB Protein DataBank，美国Brookhaven国家实验室管理生物大分子三维空间结构原子坐标数据库 http://www.rcsb.org/pdb/

- NCBI STRUCTURE MMDB （Molecular Modelling DataBase），包含了从PDB获取的实验确定的生物高聚物结构分子模型数据库

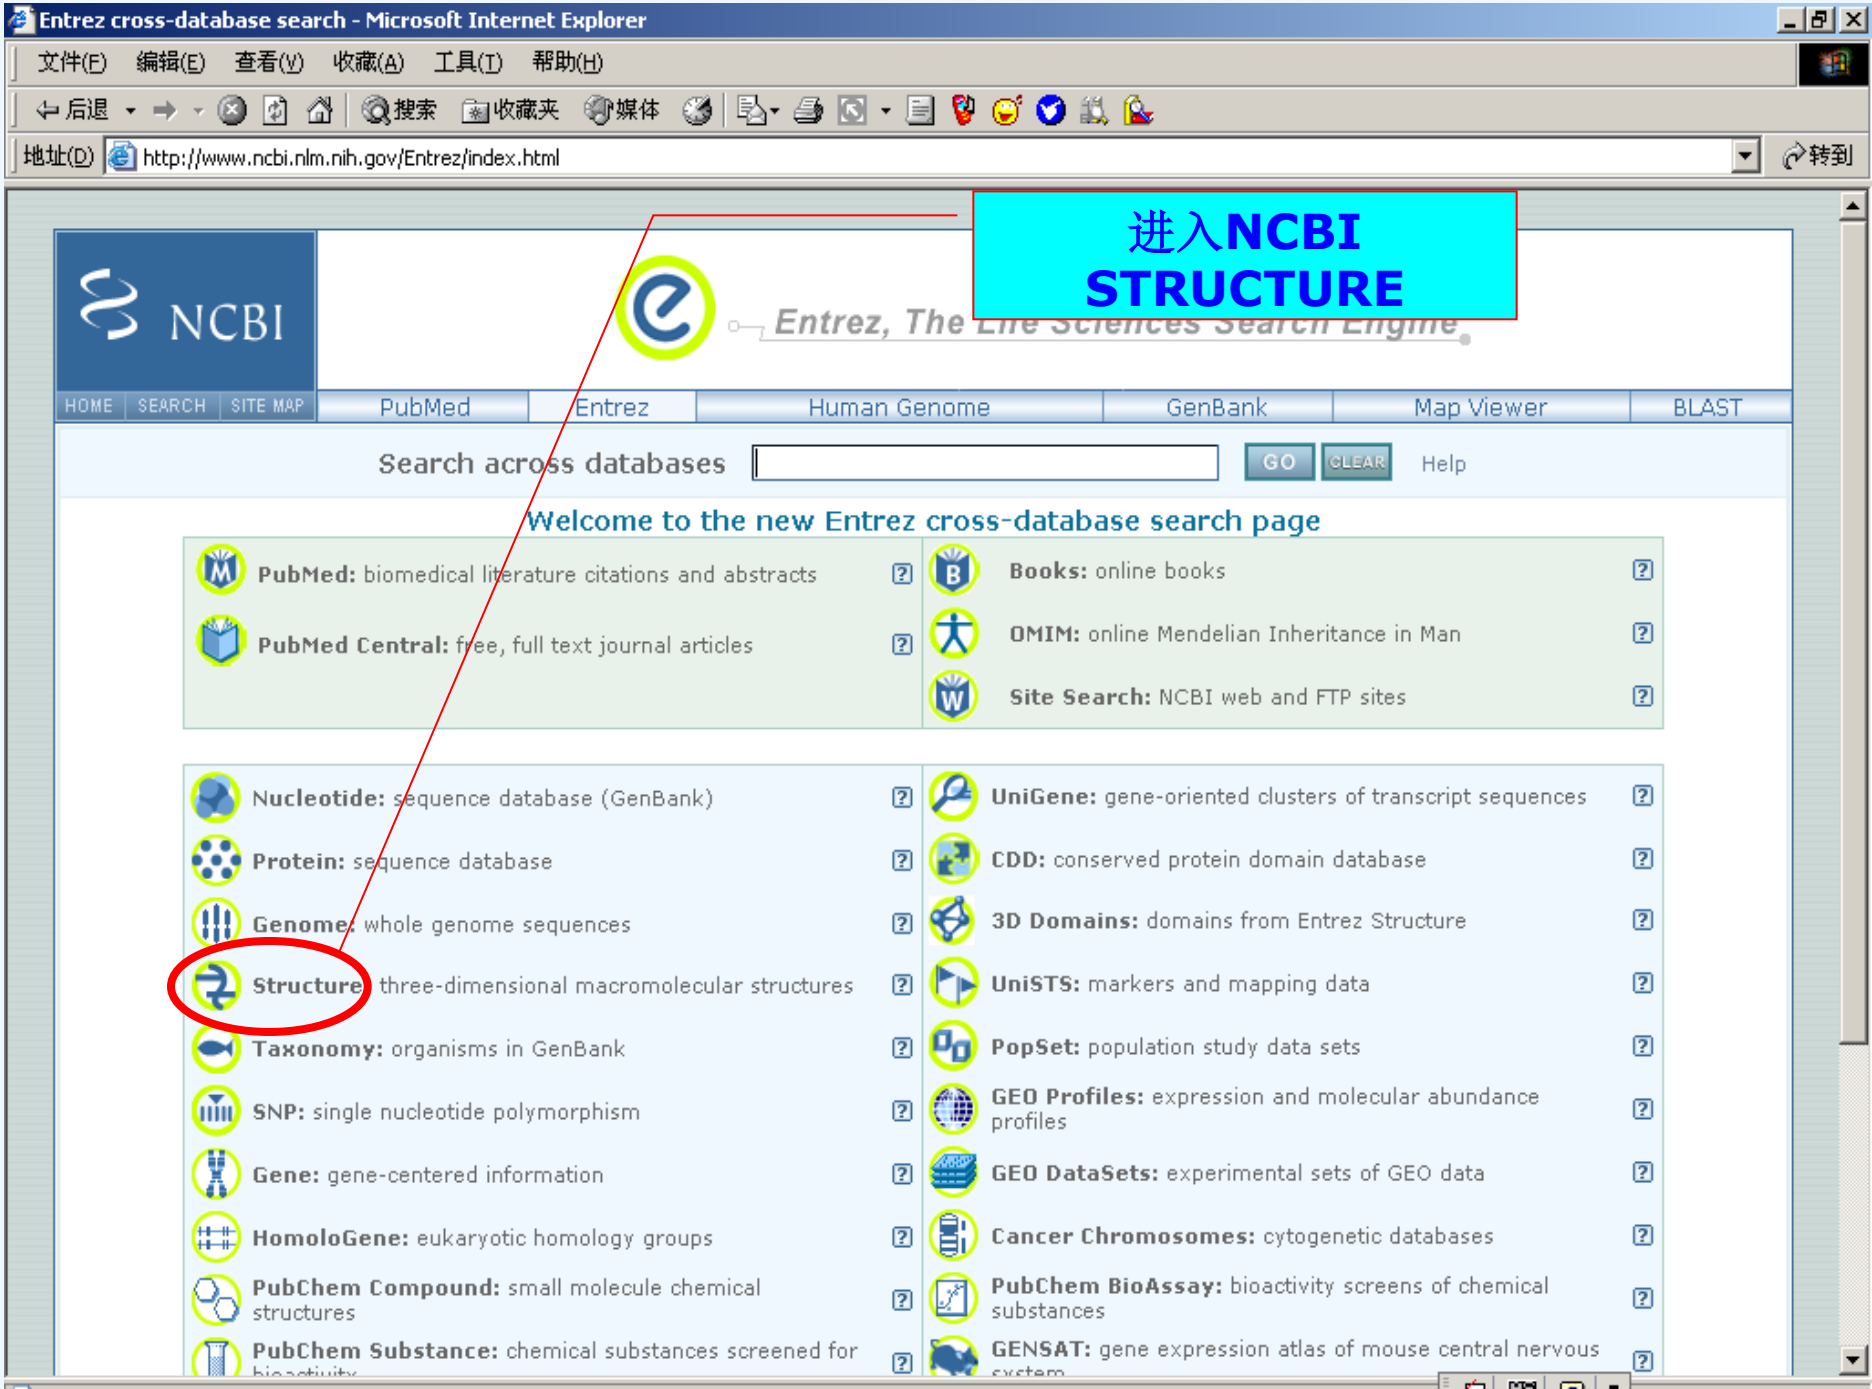
- SCOP （Structural classification of proteins） 英国医学研究会（MRC）剑桥分子生物学实验室开发的蛋白质结构分类数据库。包含描述蛋白质域的家族、超家族、折叠、等级等信息。http://scop.mrc-lmb.cam.ac.uk/scop

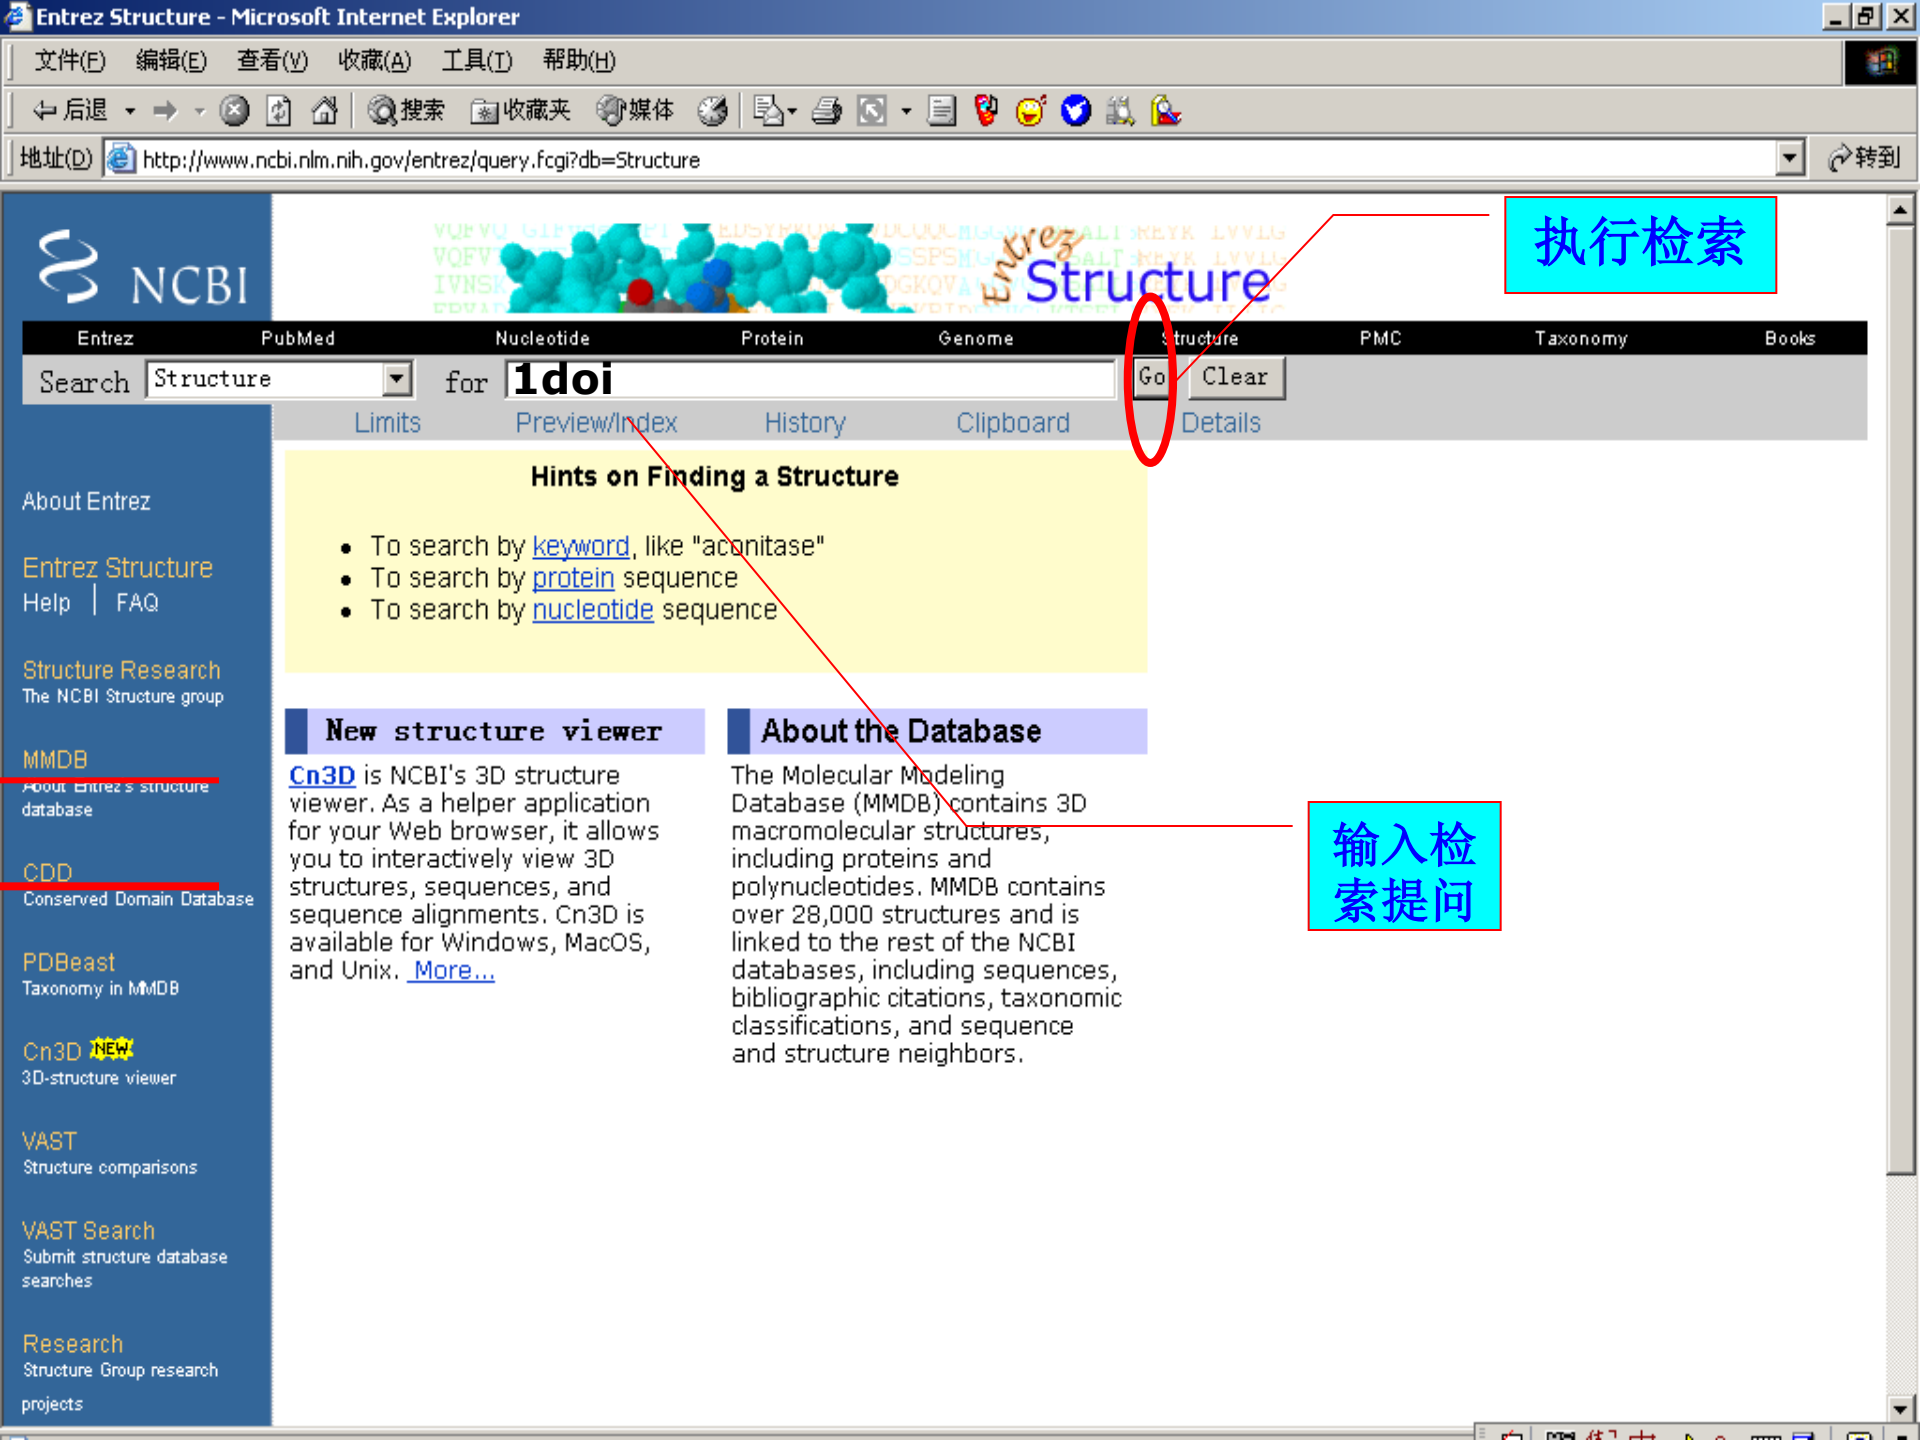
NCBI structure

提供为研究蛋白质三维(3D) 结构集成的二个数据库:

- 分子模型数据库(MMDB),提供关于各种蛋白质的结构信息;
- 蛋白质域数据库(CDD),提供在proteins(CDs)内保存的功能领域序列和结构对准表达目录。

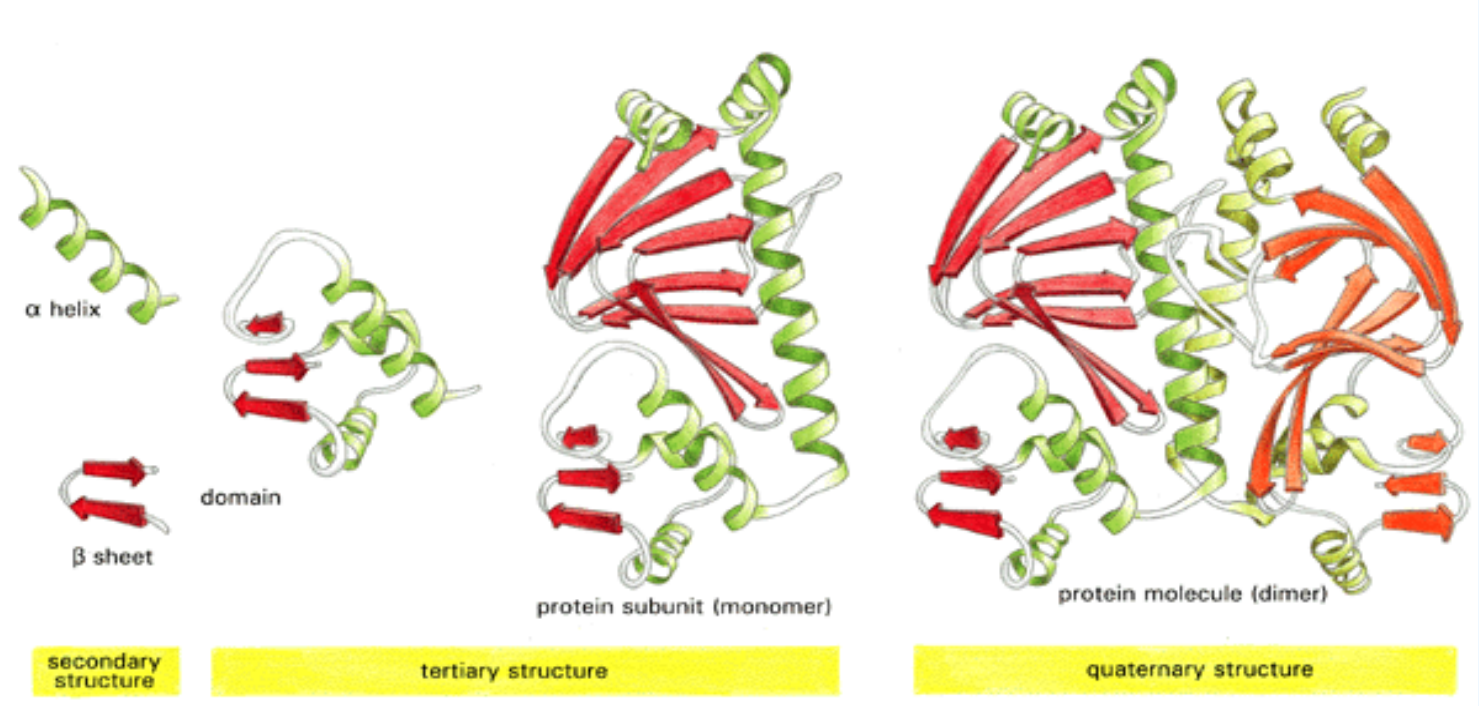
这两个数据库让科学家检索和观看结构,从结构上查找特定蛋白质的相似蛋白质，并且辨认功能位点。


Entrez cross-database search - Microsoft Internet Explorer
文件(F) 编辑(E) 查看(V) 收藏(A) 工具(T) 帮助(H)
后退 搜索 收藏夹 媒体
地址(D) http://www.ncbi.nlm.nih.gov/Entrez/index.html
转到
进入NCBI STRUCTURE
NCBI
Entrez, The Life Sciences Search Engine
HOME SEARCH SITE MAP
PubMed Entrez Human Genome GenBank Map Viewer BLAST
Search across databases
GO CLEAR Help
Welcome to the new Entrez cross-database search page
PubMed: biomedical literature citations and abstracts
PubMed Central: free, full text journal articles
Books: online books
OMIM: online Mendelian Inheritance in Man
Site Search: NCBI web and FTP sites
Nucleotide: sequence database (GenBank)
Protein: sequence database
Genome: whole genome sequences
Structure: three-dimensional macromolecular structures
Taxonomy: organisms in GenBank
SNP: single nucleotide polymorphism
Gene: gene-centered information
HomoloGene: eukaryotic homology groups
PubChem Compound: small molecule chemical structures
PubChem Substance: chemical substances screened for
UniGene: gene-oriented clusters of transcript sequences
CDD: conserved protein domain database
3D Domains: domains from Entrez Structure
UniSTS: markers and mapping data
PopSet: population study data sets
GEO Profiles: expression and molecular abundance profiles
GEO DataSets: experimental sets of GEO data
Cancer Chromosomes: cytogenetic databases
PubChem BioAssay: bioactivity screens of chemical substances
GENSAT: gene expression atlas of mouse central nervous


Entrez Structure - Microsoft Internet Explorer
文件(F) 编辑(E) 查看(V) 收藏(A) 工具(T) 帮助(H)
后退 搜索 收藏夹 媒体
地址(D) http://www.ncbi.nlm.nih.gov/entrez/query.fcgi?db=Structure
转到
NCBI
Entrez Structure
Entrez PubMed Nucleotide Protein Genome Structure PMC Taxonomy Books
Search Structure for 1doi Go Clear
Limits Preview/Index History Clipboard Details
执行检索
输入检索提问
About Entrez
Entrez Structure
Help | FAQ
Structure Research
The NCBI Structure group
MMDB
About Entrez's structure database
CDD
Conserved Domain Database
PDBeast
Taxonomy in MMDB
Cn3D NEW
3D-structure viewer
VAST
Structure comparisons
VAST Search
Submit structure database searches
Research
Structure Group research projects
Hints on Finding a Structure
To search by keyword, like "aconitase"
To search by protein sequence
To search by nucleotide sequence
New structure viewer
Cn3D is NCBI's 3D structure viewer. As a helper application for your Web browser, it allows you to interactively view 3D structures, sequences, and sequence alignments. Cn3D is available for Windows, MacOS, and Unix. More...
About the Database
The Molecular Modeling Database (MMDB) contains 3D macromolecular structures, including proteins and polynucleotides. MMDB contains over 28,000 structures and is linked to the rest of the NCBI databases, including sequences, bibliographic citations, taxonomic classifications, and sequence and structure neighbors.

蛋白质结构分类数据库

- SCOP (Structural Classification of Proteins)
- CATH(Class, Architecture, Topology, Homology)



蛋白质结构分类数据库SCOP

- 描述了**结构和进化**关系。
- SCOP数据库从不同层次对蛋白质结构进行分类，以反映它们结构和进化的相关性。
- 第一个分类层次为家族，通常将**序列相似性程度在30%以上**的蛋白质归入同一家族，有比较明确的进化关系。
- 超家族：序列相似性较低，**结构和功能特性**表明它们有共同的进化起源，将其视作超家族。
- 折叠类型：无论有无共同的进化起源，只要**二级结构单元具有相同的排列和拓扑结构**，即认为这些蛋白质具有相同的折叠方式。在这些情况下，结构的相似性主要依赖于二级结构单元的排列方式或拓扑结构。

蛋白质结构分类数据库CATH

- 类型**C**lass、构架**A**rchitecture 、拓扑结构**T**opology和同源性**H**omology 。
- 分类基础是**蛋白质结构域**。与SCOP不同的是，CATH把蛋白质分为4类，即α主类、β主类，α–β类（α/β型和α+β型）和低二级结构类。低二级结构类是指二级结构成分含量很低的蛋白质分子。
- CATH数据库的第二个分类依据为由α螺旋和β折叠形成的超二级结构排列方式，而不考虑它们之间的连接关系。

蛋白质结构分类数据库CATH

- 第三个层次为**拓扑结构**，即二级结构的形状和二级结构间的联系。
- 第四个层次为**结构的同源性**，它是先通过序列比较然后再用结构比较来确定的。
- CATH数据库的最后一个层次为**序列(Sequence)层次**，在这一层次上，只要结构域中的序列同源性大于35%，就被认为具有高度的结构和功能的相似性。对于较大的结构域，则至少要有60%与小的结构域相同。

数据库介绍 - PROSITE

- **PROSITE 主要保存两类信息：模式（pattern）和谱（profile，权重矩阵）。**
  - **模式可以理解为保守的氨基酸排列方式，通常以氨基酸单字母方式排列.**
  - **Profile 为对保守区域每一位置氨基酸保守情况进行打分构建的权重矩阵。**

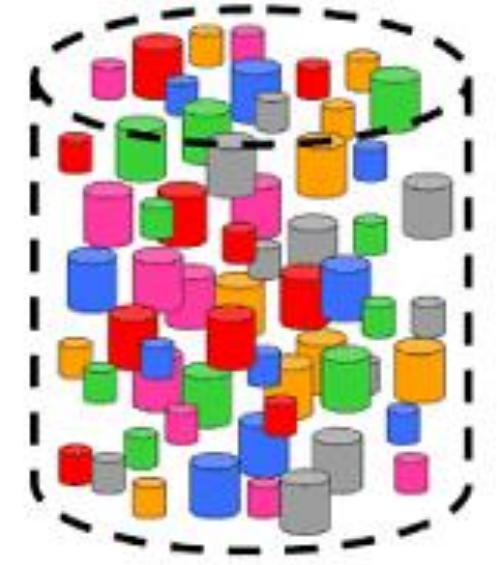
- **Pattern主要可以用来预测某些生物活性位点，如磷酸化位点、甲基化位点。profile预测可靠性高，可以用来对新蛋白进行分类和提供功能提示。**

- **蛋白的功能位点是与其三维结构紧密相关的，局部区域符合某种pattern不能保证一定会具有对应的性质，要根据实际情况，谨慎对待pattern 预测结果。**

补充：蛋白结构域数据库

- 还有很多其它结构域数据库，比较著名的有:
-
- Pfam http://www.sanger.ac.uk/Software/Pfam/search.shtml
- SMART http://smart.embl-heidelberg.de/
- BLOCKS http://www.blocks.fhcrc.org
- PRINTS http://www.bioinf.man.ac.uk/fingerPRINTScan/

数据库检索工具及分析



- Entrez
- SRS

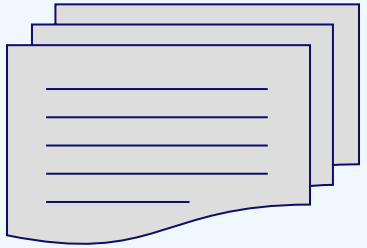
生物信息学数据库检索

- **集成检索系统：**
- Entrez系统（整合库）美国生物技术信息中心研制
- http://www.ncbi.nlm.nih.gov

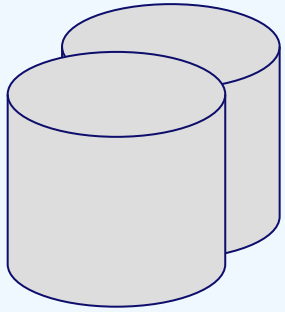
- SRS系统(Sequence Retrieval System)欧洲分子生物学实验室开发http://srs.ebi.ac.uk/
- 可开放式安装100多个数据库，北京大学安装了78个数据库

生物信息学数据的表示形式

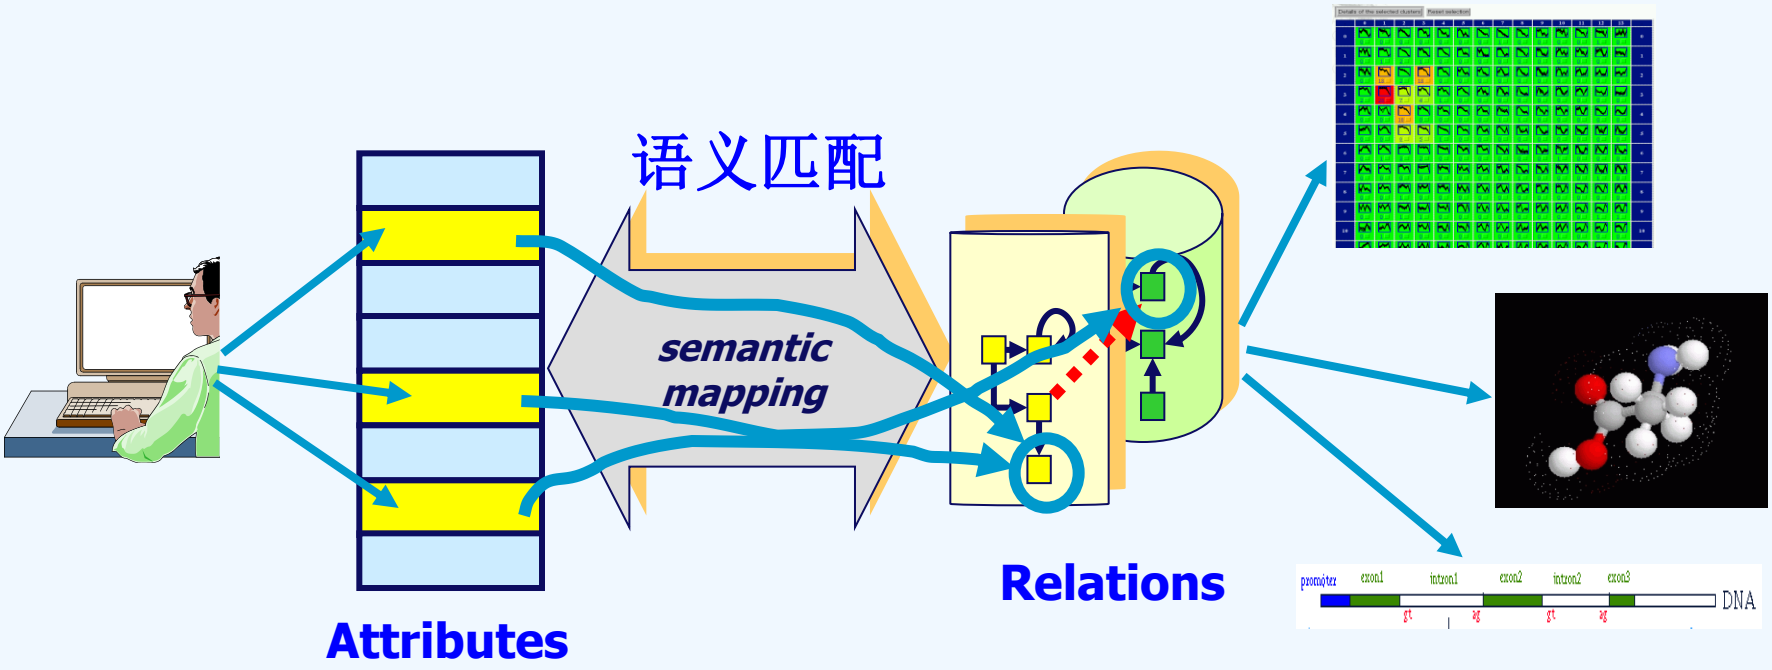
- **平面文件 (flat-file)**
  - 信息在文件中顺序存放且具有特定格式
  - 记录(Entry)通过“获得号”(accession #)唯一确定
  - 同一文件间和不同文件间信息的联系均通过accession #实现



- **关系数据库 (relational DB)**
  - 基于实体联系模型 (E-R模型)
  - 表中的记录(record/tuple)键唯一确定
  - 表之间通过外键建立联系



信息表示：关系数据库



查询

语义映射
和处理过程

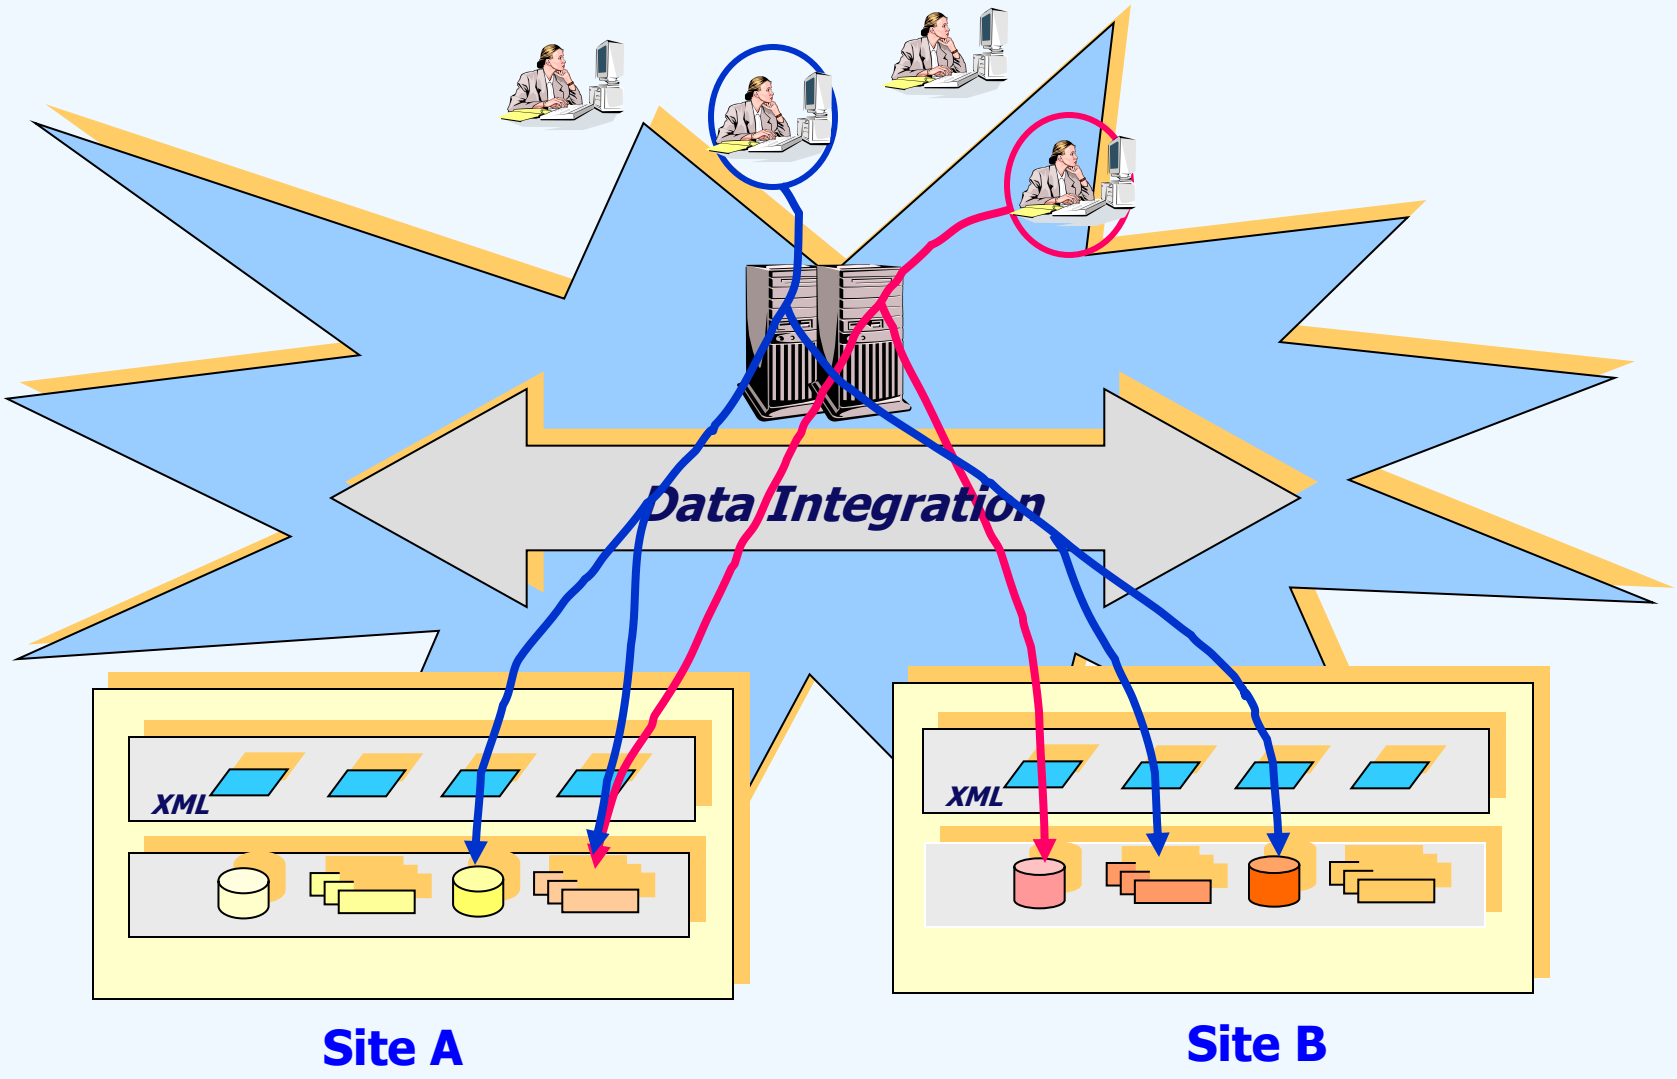
结果

生物信息学数据存在的问题

- 信息源分布在世界各地不同的站点上
- 涉及多个数据源的全局问题无法立刻得到答案
  - Painfully collecting unstructured information around the sites
  - Manually putting pieces together
  - Hopefully getting the right picture...
- 总之，信息源的特点是：
  - 自治的 (autonomous)
  - 分布式的 (distributed)
  - 异构的 (heterogeneous)



数据集成

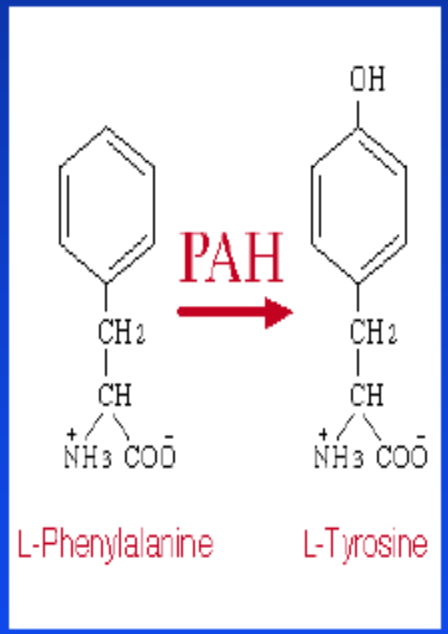


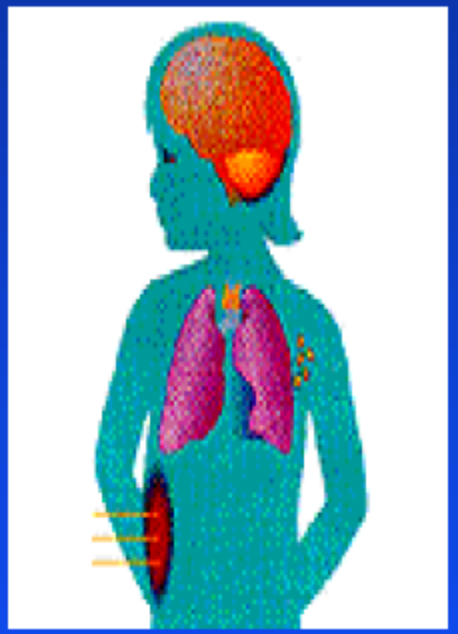
Central Paradigm of Bioinformatics

Genetic Information → Molecular Structure → Biochemical Function → Phenotype (Symptoms)

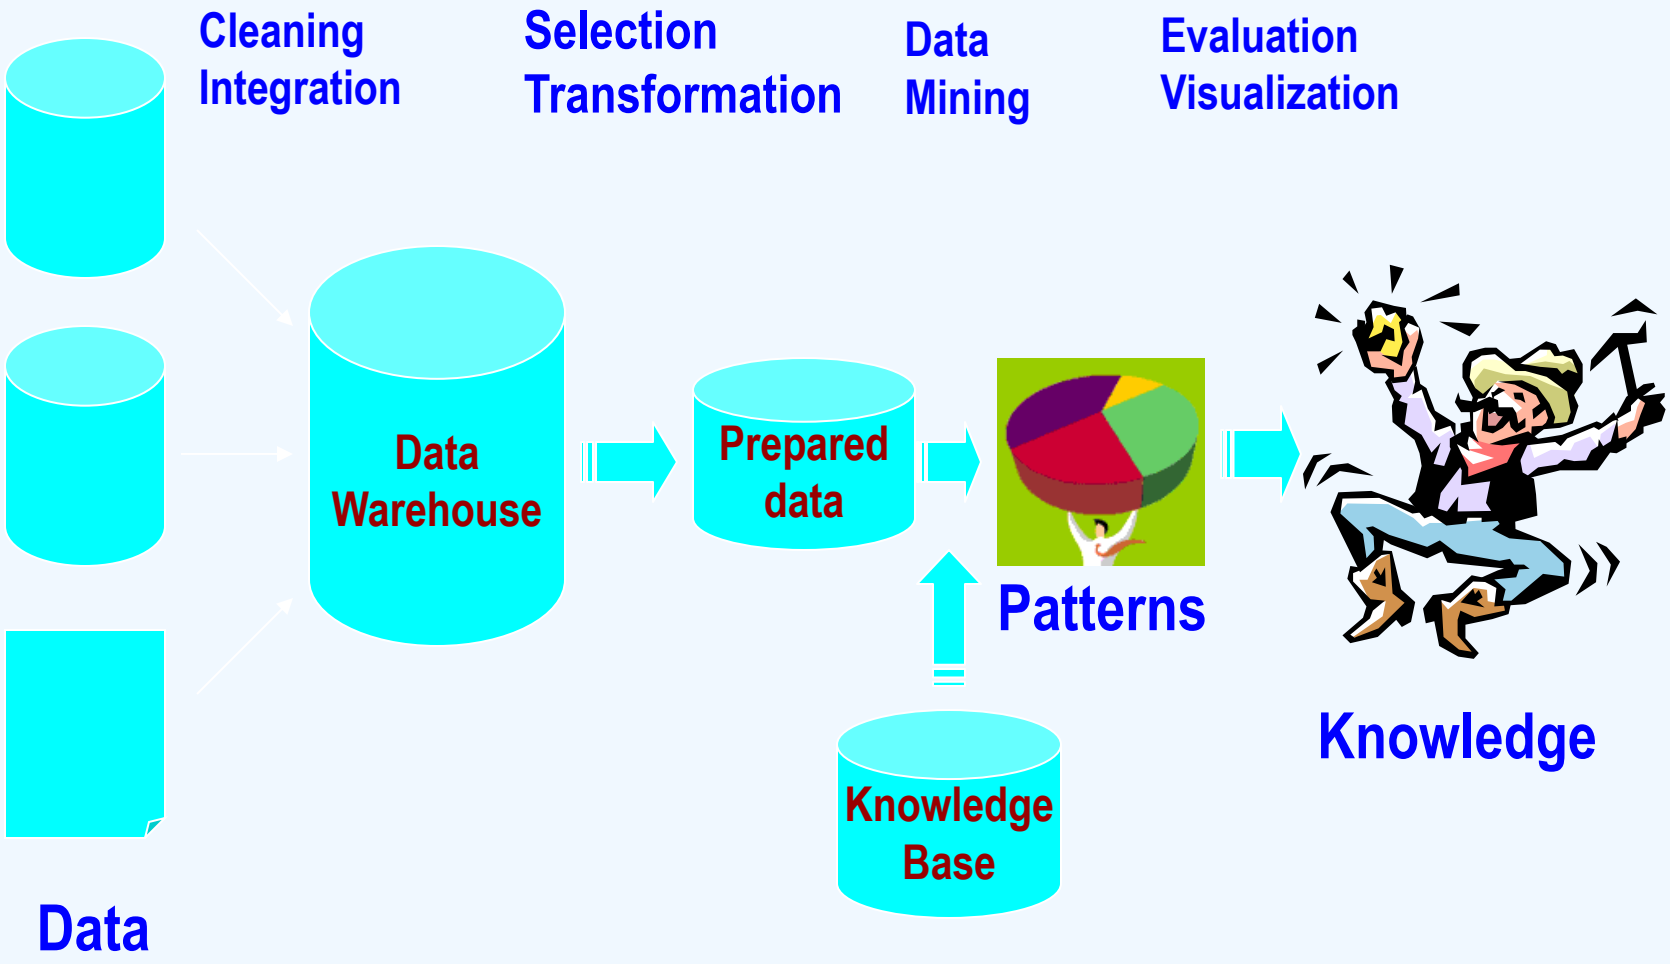
TGCTTTAGCTTT
AAACTACAGGCC
TCACTGGAGCTA
GAGACAAGAAGG
TAAAAAACGGCT
GACAAAAGAAGT
CCTGGTATCCTC
TATGATGGGAGA
AGGAAACTAGCT
AAAGGGAAGAAT
AAATTAGAGAAA
AACTGGAATGAC
GCTTATACCTGG



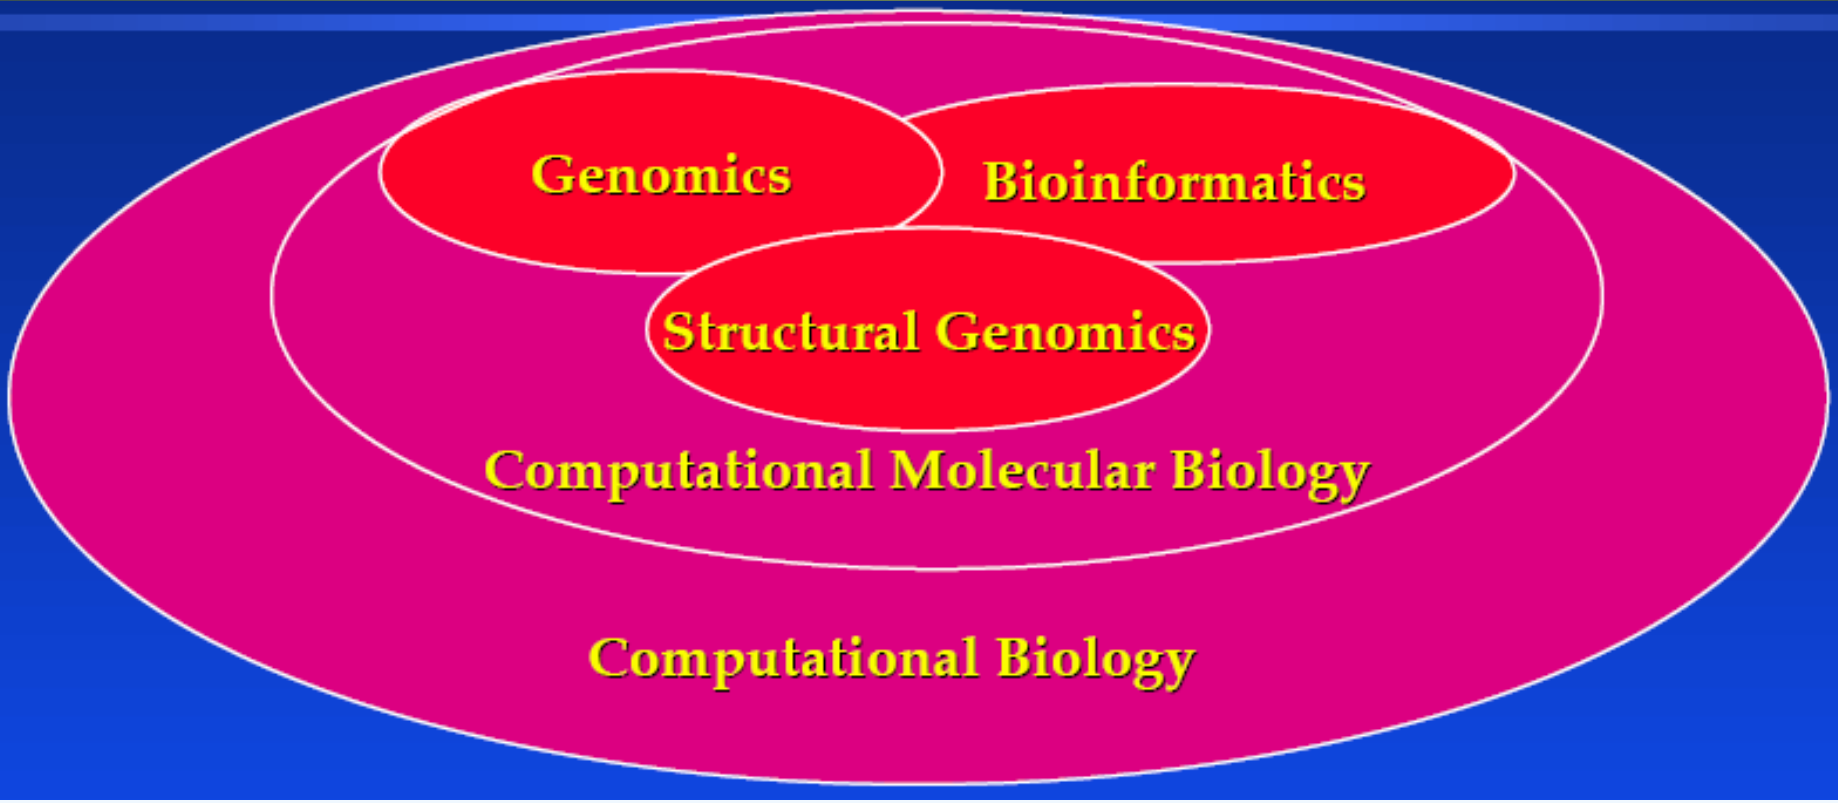




Knowledge Discovery in Databases



Genomics, Bioinformatics & Computational Biology



生物信息学最重要的任务是从海量数据中提取新知识

