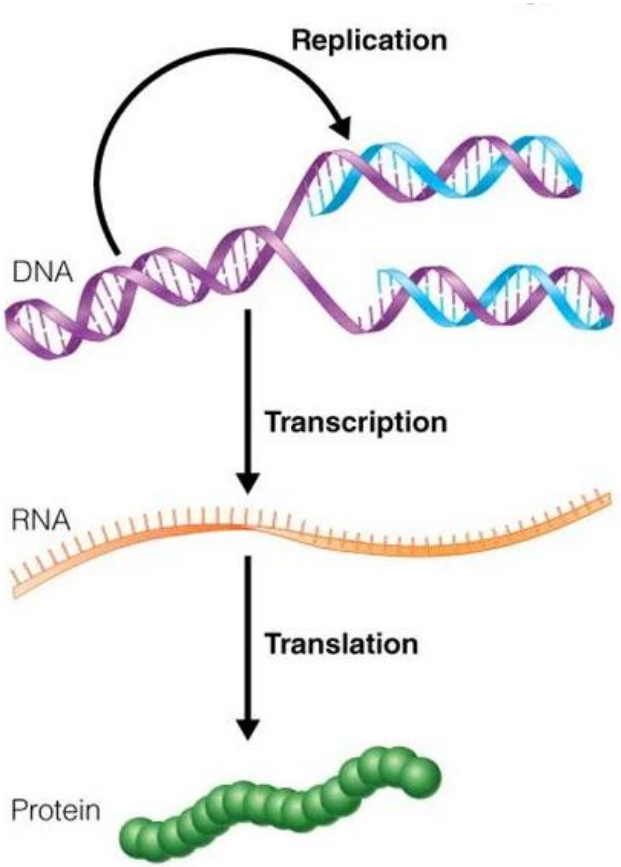
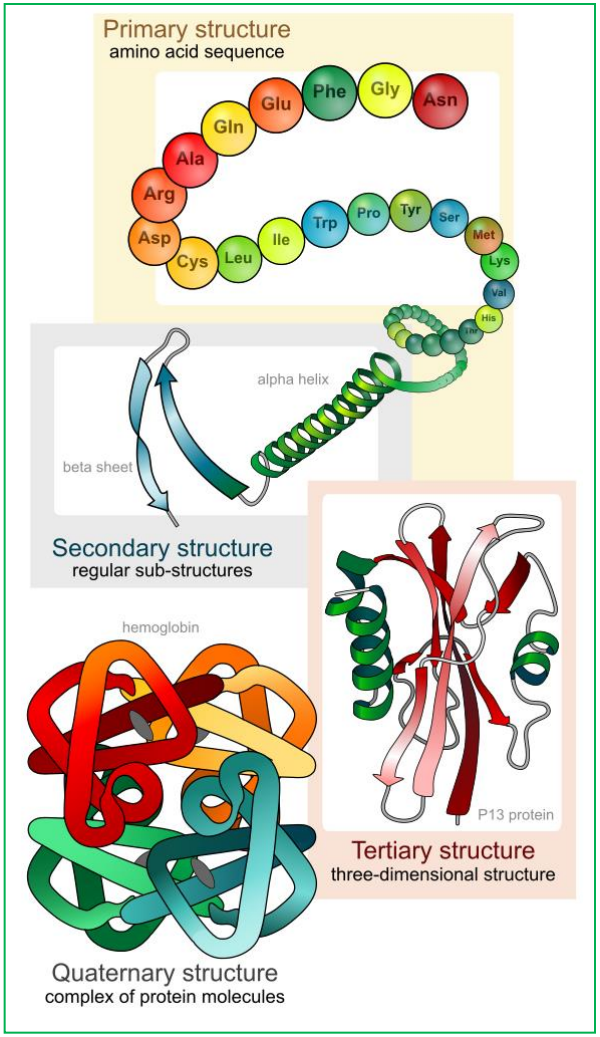
1. **蛋白质结构预测问题及二级结构预测**
2. **蛋白质三级结构预测与模拟**

Nov. 1, 2024

氨基酸序列和蛋白质高级结构间的关系是生物学中心法则的延伸，对了解生命现象的本质有重要意义

中心法则



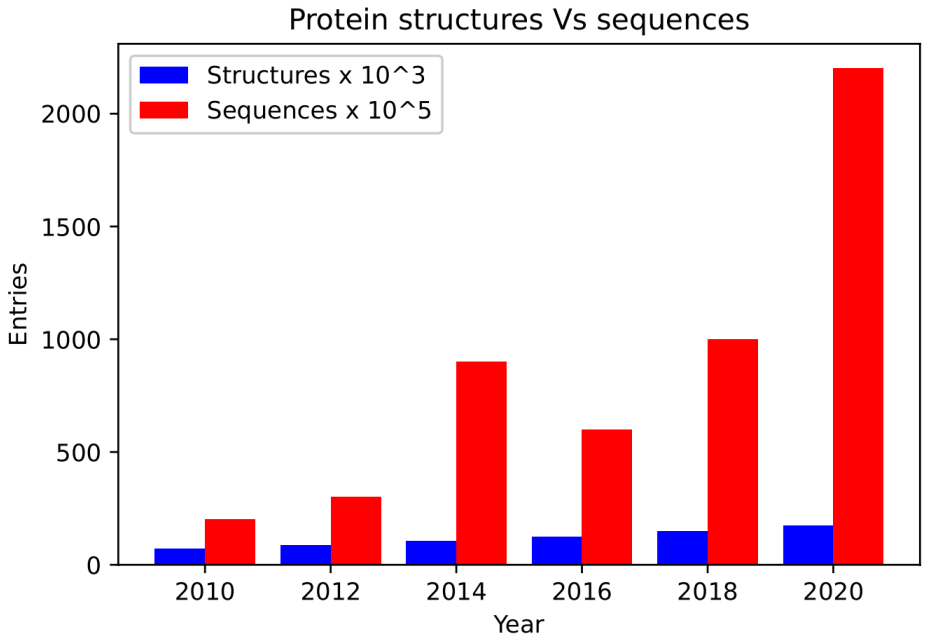


蛋白质：生命功能执行者

蛋白质结构预测问题

- **蛋白质结构预测**是指从蛋白质序列预测出其三维空间结构。
- 蛋白质的生物学功能依赖于其空间结构，因此进行蛋白质结构预测对理解蛋白质结构与功能的关系，进行蛋白质工程和药物设计具有重要意义。

蛋白质结构的测定速度
远跟不上序列的增长速度



蛋白质序列 → 空间结构

截止 2024-10-31：

已知蛋白质序列：TrEMBL 数据库：**248,266,673**

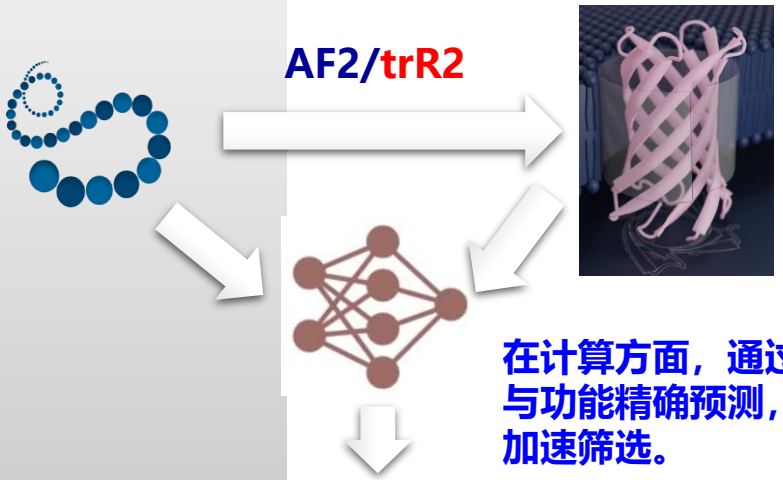
已知蛋白质3D实验结构：PDB 数据库： **227,166**

<0.1% 天然蛋白质有实验结构

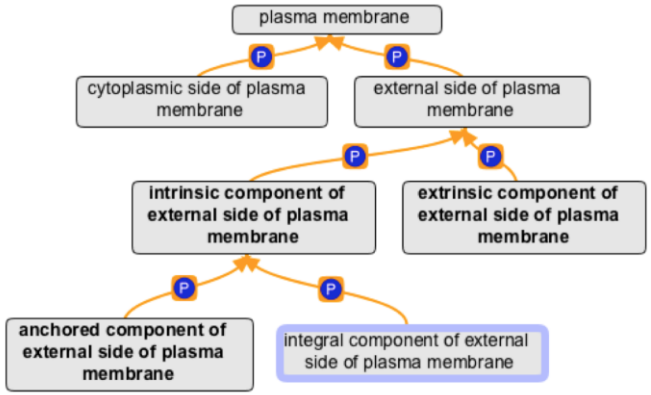
蛋白质结构预测是生物学一个无可回避的挑战！

应用之一：加速从头设计蛋白的高效筛选

膜蛋白功能预测方法MemFunc

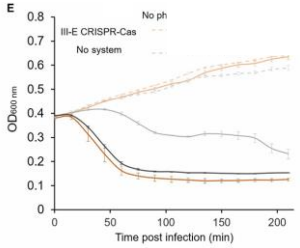


在计算方面，通过结构与功能精确预测，可以加速筛选。



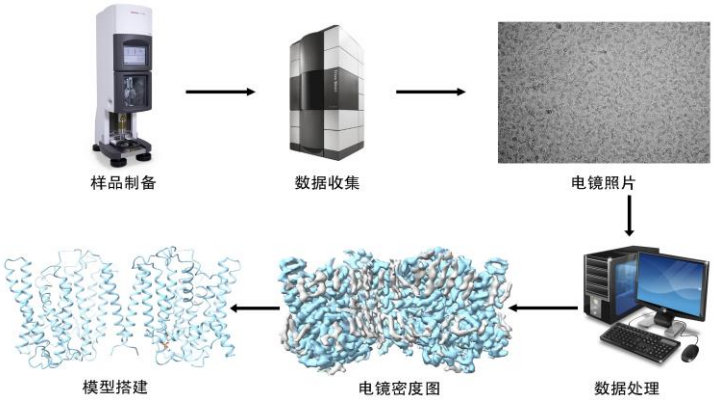
中/高通量蛋白功能性质表征





荧光示踪可折叠性、稳定性高效粗筛
高通量功能粗筛

规模化蛋白结构解析



蛋白质结构、进化与功能的关系

1、三级结构与功能的一致性

例1：肌球蛋白和血红蛋白的结构十分相似，这反映了它们进化上的关系和作为氧携带者的保守功能；但它们氨基酸序列的相似性只有39%。

例2：脂联素（AdipoQ）是一个由脂肪细胞分泌的功能未知的蛋白质。结构分析表明它与肿瘤坏死因子（TNF）有关，暗示AdipoQ也是一个信号蛋白。但是它们氨基酸序列的一致性只有9%。

2、结构与功能的非一致性

尽管蛋白质的结构对于预测其功能十分有帮助，但需注意：结构与功能之间并不是简单的一对一的关系。蛋白质具有相似的结构但经过进化以后可以执行不同的功能。

例3：α/β水解酶折叠模式具有多种功能：胆固醇酯酶、双烯内脂水解酶、神经趋化素、三酰甘油脂肪酶、丝氨酸羧肽酶、卤代烷烃脱卤酶等等。

蛋白质结构的价值

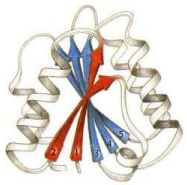
- 可能会有数以千计的假想蛋白质和已知蛋白质具有相似的关系，它们的序列分化的很远以至于不能再用序列分析检测同源关系，但是它们的结构可以识别它们之间的同源关系。
- 明显不相关的序列可能具有相似的结构。
- 结构蛋白组学的目标就是发现每一个蛋白质折叠家族中的代表成员，并解析其结构，为结构比较提供模板。这种结构的比较可以用于假想蛋白质的功能注释，甚至再序列分析显示不同源的情况下也可以提供功能信息。

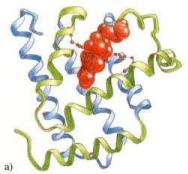
蛋白质结构预测问题的可行性

- 自然界中实际存在的蛋白质种类是有限的，已知的结构类型并不多
  - 结构的数目并未随蛋白质氨基残基的个数呈现指数增长
- 存在大量同源序列，序列到结构的关系有一定规律可循
  - 相似的序列具有相似的结构

….-Gly-Ala-Glu-Phe-
Ala- Glu-Phe-Glu-
Phe-….



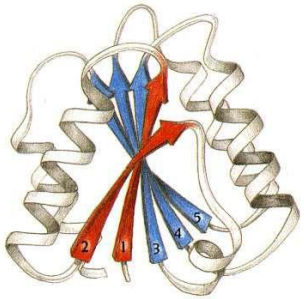




蛋白质结构预测问题的数学本质

- 寻找一种从蛋白质的氨基酸线性序列到蛋白质所有原子三维坐标的一种映射

….-Gly-Ala-Glu-Phe-Ala-Glu-Phe-Glu-Phe-….



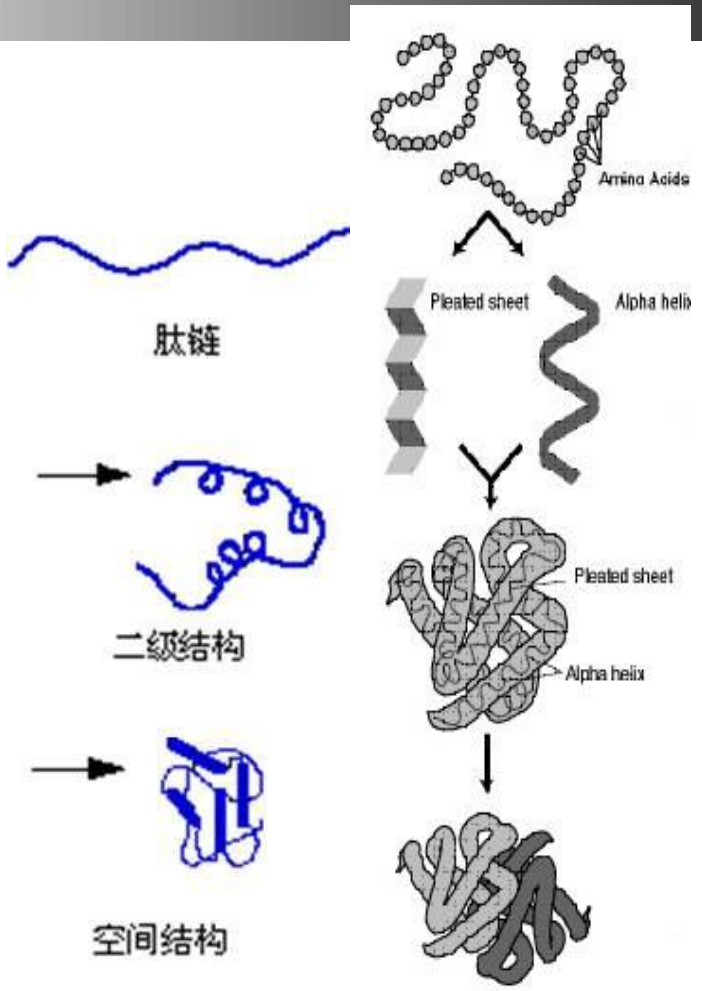
结构预测的基本方法

- 统计分析方法
  - 对已知结构的蛋白质进行统计分析，建立氨基酸序列到蛋白质结构的映射模型，进而对未知结构的氨基酸序列根据映射模型直接从序列预测结构
    - 经验参数法
    - 相似片断法
    - 同源方法

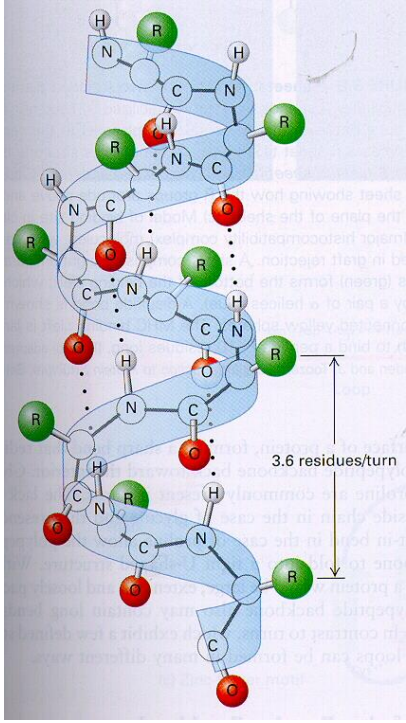
- 理论分析方法
  - **假设蛋白质分子取能量最低的空间结构**，根据物理化学原理，通过理论计算(如分子力学/分子动力学)进行对氨基酸序列结构预测
    - 从头计算法

蛋白质的空间结构

- 构成蛋白质的氨基酸序列的长度不同、排列不同和空间结构不同
  - 一级结构
    - 蛋白质中相邻的氨基酸通过肽键形成一条伸展的链
  - 二级结构
    - 肽链上的氨基酸残基形成局部的二级结构
    - 比如α螺旋是氨基酸的单链螺旋，而β片层则由序列片段“织”形成平面片状结构
  - 空间结构
    - 各种二级结构组合形成完整的折叠结构



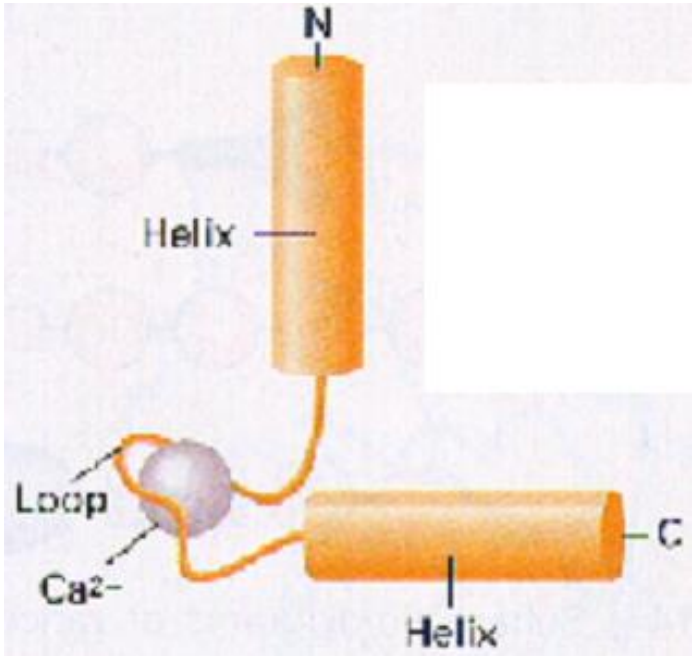
蛋白质二级结构预测



二级结构：主要是主链氢键维持的结构

- α - 螺旋（α-helix）
- β - 折叠（β-sheet）
- 转角（turn）

二级结构的预测是蛋白结构预测的第一步。



二级结构预测可利用的信息

- 单个氨基酸残基统计分析
  - 从数据集中提取各种残基形成特定二级结构的倾向，以此作为预测依据
- 基于氨基酸片断的统计分析
  - 统计对象氨基酸片断，片断体现了中心残基所处的环境
  - 以残基在特定环境中形成的特定二级结构的倾向作为预测依据
- 蛋白质序列的长程信息和进化信息
  - 二级结构的形成一定程度上受到长程残基的影响
  - 蛋白质家族具有特异的残基替换模式
  - 存在进化保守区域，该区域变化则会导致蛋白质结构的改变

蛋白质二级结构预测方法

经验参数法

- 蛋白质二级结构的组成规律性比较强
- 三种基本二级结构平均占氨基酸残基的85%
- 各种二级结构非均匀地分布在蛋白质中

- 二级结构预测的方法大体分为三代：

  – 第一代是基于单个氨基酸残基统计分析

    - 从有限的数据集中提取各种残基形成特定二级结构的倾向，以此作为二级结构预测的依据；
    - 经验参数法由Chou 和Fasman在70年代提出来，并不断完善；
    - 每种氨基酸出现在各种二级结构中倾向或者频率是不同的：

    例如：Glu主要出现在α螺旋中

    Asn和Gly主要分布在转角中

    Pro也常出现在转角中，但是不会出现在α螺旋中

表 7.1　20 种常见氨基酸的 Chou-Fasman 参数。

氨基酸	P_α	P_β	P_t	$f(i)$	$f(i+1)$	$f(i+2)$	$f(i+3)$
丙氨酸（A）	142	83	66	0.06	0.076	0.035	0.058
精氨酸（R）	98	93	95	0.070	0.106	0.099	0.085
天冬酰胺（N）	67	89	156	0.161	0.083	0.191	0.091
天冬氨酸（D）	101	54	146	0.147	0.110	0.179	0.081
半胱氨酸（C）	70	119	119	0.149	0.050	0.117	0.128
谷氨酸（E）	151	37	74	0.056	0.060	0.077	0.064
谷氨酰胺（Q）	111	110	98	0.074	0.098	0.037	0.098
甘氨酸（G）	57	75	156	0.102	0.085	0.190	0.152
组氨酸（H）	100	87	95	0.140	0.047	0.093	0.054
异亮氨酸（I）	108	160	47	0.043	0.034	0.013	0.056
亮氨酸（L）	121	130	59	0.061	0.025	0.036	0.070
赖氨酸（K）	114	74	101	0.055	0.115	0.072	0.095
甲硫氨酸（M）	145	105	60	0.068	0.082	0.014	0.055
苯丙氨酸（F）	113	138	60	0.059	0.041	0.065	0.065
脯氨酸（P）	57	55	152	0.102	0.301	0.034	0.068
丝氨酸（S）	77	75	143	0.120	0.139	0.125	0.106
苏氨酸（T）	83	119	96	0.086	0.108	0.065	0.079
色氨酸（W）	108	137	96	0.077	0.013	0.064	0.167
酪氨酸（Y）	69	147	114	0.082	0.065	0.114	0.125
缬氨酸（V）	106	170	50	0.062	0.048	0.028	0.053

- 二级结构预测的方法大体分为三代：

  - 第二代预测方法是基于氨基酸片段的统计分析
    - 统计的对象是氨基酸片段
    - 片段的长度通常为**11-21**
    - 片段体现了中心残基所处的环境
    - 在预测中心残基的二级结构时，以残基在特定环境形成特定二级结构的倾向作为预测依据

  - 这些算法可以归为几类，可分别基于：

（1）统计信息；（2）物理化学性质；（3）序列模式；（4）多层神经网络；（5）多元统计；（6）机器学习的专家规则；（7）最邻近算法

- **基于统计学的预测方法**

1、 Chou-Fasman方法

- **直接以氨基酸序列来预测二级结构**

统计各种氨基酸在不同二级结构中的各种构象分布概率、氨基酸在蛋白质中的相对出现概率以及残基出现在结构中的频率，最后得到构想参数，根据此参数得出氨基酸形成二级结构的倾向性，从而预测二级结构。

一个氨基酸残基的构象倾向性因子定义为

$$P_i = A_i / T_i \quad (i= \alpha,\beta,c, t)$$

式中下标i表示构象态

如α螺旋、β折叠、转角、无规卷曲等；

T_i是所有被统计残基处于构象态i的比例；

A_i是第A种残基处于构象态i 的比例；

P_i大于1.0表示该残基倾向于形成二级结构构象i，小于1.0则表示倾向于形成其它构象。

发现关于二级结构的经验规则

基本思想是在序列中寻找规则二级结构的成核位点和终止位点。

- 扫描输入的氨基酸序列，利用一组规则发现可能成为特定二级结构成核区域的短序列，然后对于成核区域进行扩展，不断扩大成核区域，直到倾向性因子小于1.0为止。
- 规则：
  - （i）α螺旋规则
  - （ii）β折叠规则
  - （iii）转角规则
  - (iv) 重叠规则



Chou-Fasman二级结构预测经验规则

- **α 螺旋规则**
  - 相邻的6个残基中如果有至少4个残基倾向于形成α螺旋，则认为是螺旋核。
  - 然后从螺旋核向两端延伸，直至四肽α螺旋倾向性因子的平均值p_α<1.0为止。此外，不容许脯氨酸在螺旋内部出现，但可出现在C末端以及N端的前三位。
  - 最后，将α螺旋两端各去掉3个残基，剩余部分多于6个残基，且p_α>1.3，则为α螺旋。

Chou-Fasman二级结构预测经验规则

- β 折叠规则
  - 如果相邻5个残基中若有3个倾向于形成β折叠，则认为是β折叠核。
  - β折叠核向两端延伸直至4个残基的平均折叠倾向因子 p_β<1.0。若延伸后片段的p_β>1.05，则预测为β折叠。

Chou-Fasman二级结构预测经验规则

● 转角规则

- 四肽片段，若位置专一性转角形成几率$f_{i+1}f_{i+2}f_{i+3}f_{i+4}$ >$7.5*10^{-5}$，p_t>1.0，并大于p_α和p_β，则预测为转角。

● 重叠规则

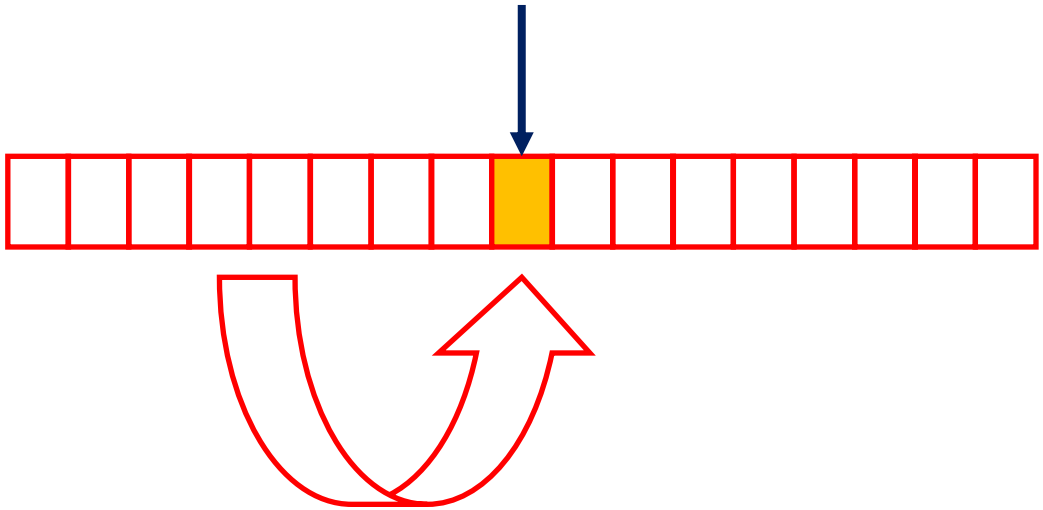
- 螺旋和折叠的重叠区域，按p_α和p_β的相对大小进行预测，若p_α>p_β，则预测为螺旋，反之为折叠。

2、GOR方法

- 是一种基于信息论和贝叶斯统计学的方法
- GOR将蛋白质序列当作一连串的信息值来处理
- GOR方法不仅考虑被预测位置本身氨基酸残基种类的影响，而且考虑相邻残基种类对该位置构象的影响

相邻氨基酸之间存在相互作用，蛋白质序列中某一位置的二级结构主要是由17个连续的氨基酸（包括一个中心氨基酸、与其N端相连的8个氨基酸残基、与其C端相连的8个氨基酸残基）决定。

序列窗口　　中心残基



窗口中各个残基对中心残基二级结构的支持程度

3. Lim方法——立体化学方法

- 氨基酸的理化性质对二级结构影响较大。Lim方法根据氨基酸残基的物理化学性质，包括：疏水性、亲水性、带电性以及体积大小等，并考虑残基之间的相互作用组合预测可能形成的二级结构。对于小于50个氨基酸残基的肽链，Lim方法的预测准确率可以达到73%.
- “疏水性”是氨基酸的一种重要性质，疏水性的氨基酸倾向于远离周围水分子，将自己包埋进蛋白质的内部。

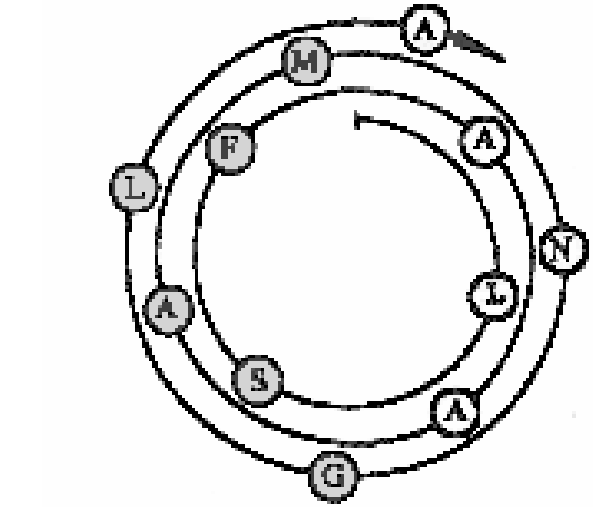


图 7.2　酒石酸合成酶中一段 α 螺旋结构的剖面图

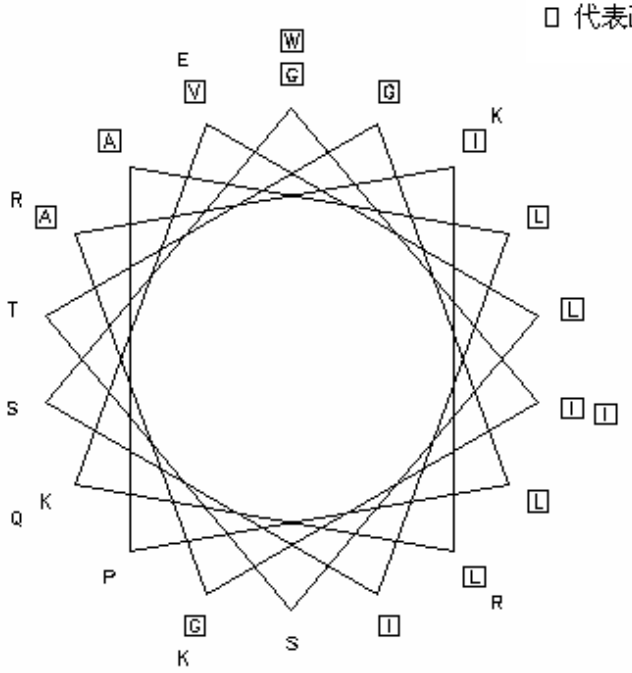


图 7.2 利用 HELICALWHEEL 程序画出的蛋白质蜂毒素的旋轮图。

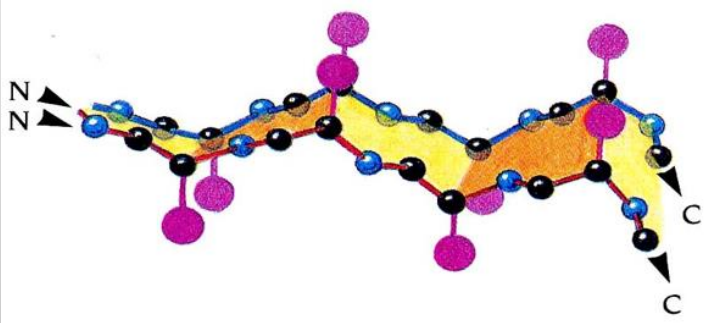
α螺旋的形成规律：

•在一段序列中发现第i、i+3、i+4位（如1、4、5）是疏水残基时，这一片段就被预测为α螺旋；

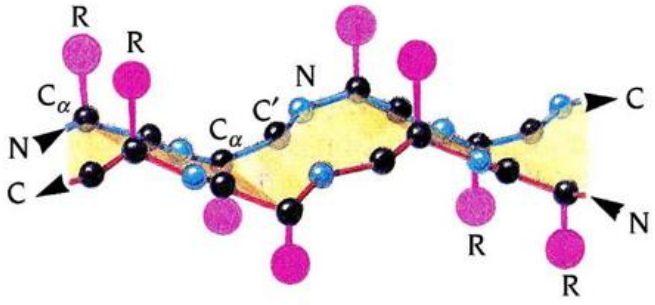
• 当发现第i、i+1、i+4位（如7，8，11）为疏水残基时，这一片段也被预测为α螺旋。

对于β折叠的形成规律：

- 对于β折叠，也存在着一些特征的亲疏水残基间隔模式，埋藏的β折叠通常由连续的疏水残基组成，一侧暴露的β折叠则通常具有亲水-疏水的两残基重复模式。



平行



反向平行

•原则上，通过在序列中搜寻特殊的亲疏水残基间隔模式，就可以预测α螺旋和β折叠。

4. 同源分析法

- 将待预测的片段与数据库中已知二级结构的片段进行相似性比较，利用打分矩阵计算出相似性得分，根据相似性得分以及数据库中的构象态，构建出待预测片段的二级结构。
- 该方法对数据库中同源序列的存在非常敏感，若数据库中有相似性大于30%的序列，则预测准确率可大大上升。

假设已知二级结构的氨基酸片段

T=STNGIYW

T的二级结构为

CHHHHHT

H代表α螺旋，

T代表转角，

C代表无规卷曲

待预测二级结构的氨基酸片段

U=ATSGVFL

序列比对：

T = S T N G I Y W

U = A T S G V F L

直接将T的构象态赋予U

- 更为合理的方法：

  是将待预测二级结构的蛋白质U与多个同源序列进行多重比对，对于U的每个残基位置，其构象态由多个同源序列对应位置的构象态决定，或取出现次数最多的构象态，或对各种可能的构象态给出得分值。

- 第一代和第二代预测方法对三态预测的准确率都小于70%，而对β折叠预测的准确率仅为28~48%
  - 其主要原因是只利用局部信息
- 第三代方法（考虑多条序列）
  - 运用长程信息和蛋白质序列的进化信息
  - 准确度有了比较大的提高

利用进化信息预测蛋白质的二级结构

- 蛋白质序列家族中氨基酸的替换模式是高度特异的，如何利用这样的进化信息是二级结构预测的关键。
- 蛋白质二级结构预测软件系统PHD
  - 第一步工作是形成同源序列的多重对比排列
  - 第二步工作是将得到的多重比对的统计结果送到一个神经网络中计算。

蛋白质的进化

- 同源蛋白质：从一个祖先进化而来，往往具有相关功能，并采取相似的三维结构。
- 类似蛋白质：采用相似的三维结构，但序列的相似性较低。
- 识别同源蛋白和类似蛋白是结构预测的一个重要课题，也是预测基础。

- 单序列预测所提供的信息只是残基的顺序而没有其空间分布的信息，所以单序列预测的算法预测准确率并不高，而且对于一些特殊结构，这些算法很难预测成功。
- 多序列列线预测和神经网络的应用大大提高了二级结构预测的准确度，通过对序列比对的预测可以明确的提供单一位点在三维结构上的信息。

6. 综合方法

- 综合方法不仅包括各种预测方法的综合，而且也包括结构实验结果、序列对比结果、蛋白质结构分类预测结果等信息的综合。

  - 多个程序同时预测，综合评判 → 一致结果
  - 序列比对与二级结构预测
  - 双重预测

    首先预测蛋白质的结构类型

    然后再预测二级结构

- 最常用的是PHD方法。PHD结合了许多神经网络的成果，每个结果都是根据局部序列上下文关系和整体蛋白质性质（蛋白质长度、氨基酸频率等）来预测残基的二级结构。最终的预测是这些神经网络每个输出的算术平均值。
- 这种结合方案被称为陪审团决定法（jury decision）或者称为所有胜利者（winner-take-all）法。PHD被认为是二级结构预测的标准。

ExPASy
Bioinformatics Resource Portal

Secondary structure prediction

- AGADIR - An algorithm to predict the helical content of peptides
- APSSP - Advanced Protein Secondary Structure Prediction Server
- CFSSP - Chou & Fasman Secondary Structure Prediction Server
- GOR - Garnier et al, 1996
- HNN - Hierarchical Neural Network method (Guermeur, 1997)
- HTMSRAP - Helical TransMembrane Segment Rotational Angle Prediction
- Jpred - A consensus method for protein secondary structure prediction at University of Dundee
- JUFO - Protein secondary structure prediction from sequence (neural network)
- NetSurfP - Protein Surface Accessibility and Secondary Structure Predictions
- NetTurnP - Prediction of Beta-turn regions in protein sequences
- nnPredict - University of California at San Francisco (UCSF)
- Porter - University College Dublin
- PredictProtein - PHDsec, PHDacc, PHDhtm, PHDtopology, PHDthreader, MaxHom, EvalSec from C
- Prof - Cascaded Multiple Classifiers for Secondary Structure Prediction
- PSA - BioMolecular Engineering Research Center (BMERC) / Boston
- PSIpred - Various protein structure prediction methods at Bloomsbury Centre for Bioinformatics
- SOPMA - Geourjon and Delage, 1995
- Scratch Protein Predictor
- DLP-SVM - Domain linker prediction using SVM at Tokyo University of Agriculture and Technology

http://www.expasy.ch/tools/

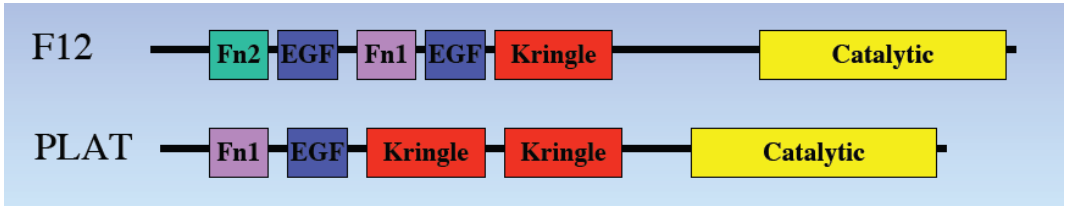
历史上蛋白质二级结构预测的用途

- 蛋白质或其突变体的设计
- 确定蛋白质间结构和功能的关系
- 建立正确的序列比对关系
- 三级结构预测的基础
- 有助于晶体结构的解析

蛋白质结构域预测

结构域（Structural Domain）是蛋白序列的功能、结构和进化单元。结构域通常都是几个超二级结构单元的组合，即蛋白质多肽链在二级结构的基础上进一步卷曲折叠成几个相对独立的近似球形的组装体。结构域是介于二级和三级结构之间的另一种结构层次。

结构域的实质是二级结构的组合体，充当三级结构的元件。

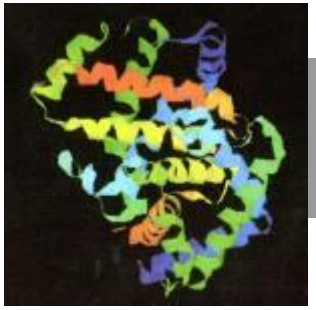


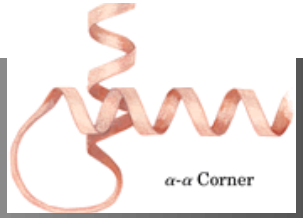


基本类型：

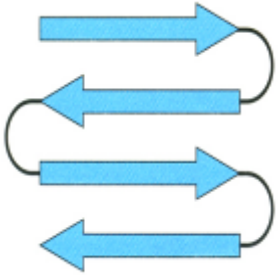
α折叠







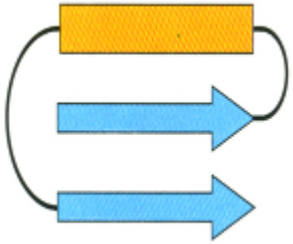
β折叠



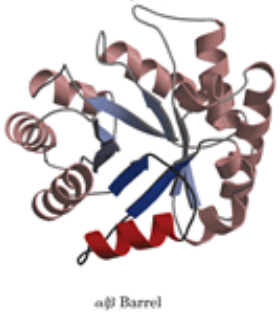




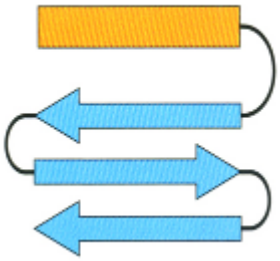
α/β折叠

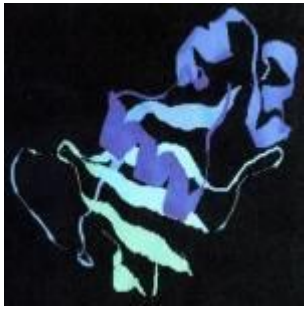






α+β折叠





蛋白质结构域数据库

工具	网站	备注
CDD	http://www.ncbi.nlm.nih.gov/sites/entrez?db=cdd	通过比较目标序列和一组位置特异性打分矩阵进行RPS-BLAST来确定目标序列中的保守结构域
HAMAP	http://expasy.org/sprot/hamap/families.html	通过专家预测系统产生的微生物家族同源蛋白数据
InterPro	**http://www.ebi.ac.uk/interpro/**	**蛋白质家族、结构域和功能位点的联合资源数据库，整合了多个数据库和工具的结果，并提供相应的链接**
Pfam	http://pfam.sanger.ac.uk/	每个蛋白家族包含了多序列比对、profile-HMMs和注释文件
ProDom	http://prodom.prabi.fr/	从SWISS-PROT/TrEMBL数据库中的非片段蛋白序列数据构成，每条记录包含一个同源结构域多重比对和家族保守一致性序列
SMART	http://smart.embl-heidelberg.de/	由EMBL建立，集成了大部分已知蛋白功能域数据，注释包括了功能类型、三维结构、分类信息

蛋白质三级结构预测

- 同源建模
- 折叠识别
- 从头预测

1. 同源模型法

- 基本思想：
  - 通过同源序列分析预测蛋白质的空间结构或空间结构单元
- 基本原理：
  - 具有相似序列的蛋白质倾向于折叠成相似的空间结构
    - 每一个自然蛋白质具有一个特定的结构，不同的序列会采用同一个基本折叠
    - 一对自然进化的蛋白质，如果它们的序列具有25~30%的等同部分或更多，则可以假设这两个蛋白质折叠成相似的空间结构
    - 如果一个未知结构的蛋白质序列与一个已知结构的蛋白质序列具有足够的序列相似性，那么可以根据相似性原理给未知结构的蛋白质构造一个近似的三维模型
    - 如果目标蛋白质序列的某一部分与已知结构的蛋白质的某一结构域区域相似，则可以认为目标蛋白质具有相同的结构域或者功能区域

同源建模基本包括如下几个步骤：

1. 使用未知序列搜索已知蛋白质结构。
2. 产生未知序列和模板序列最可能的完整比对。
3. 以模板结构骨架为模型，建立蛋白质骨架模型。
4. 在靶序列或者模板序列的有空位区域，使用环建模过程代替合适长度的片段。
5. 给骨架模型加上侧链。
6. 优化侧链的位置。
7. 使用能量最小和已知的优化知识来优化结构。

同源模型法

- 三维空间结构预测结果
  - 若有60%等同的序列，则所建立的三维模型非常准确
  - 若序列的等同部分超过60%，则预测结果将接近于实验得到的测试结果
  - 如果序列的等同部分大于30%，则可以期望得到比较好的预测结果

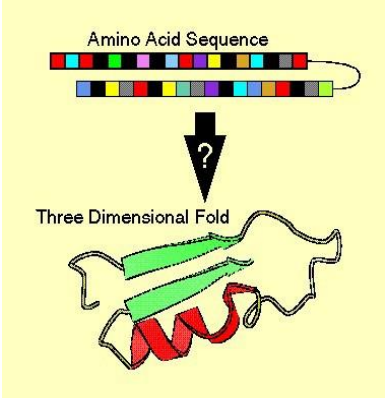
2. 线索化方法（折叠识别）

- 提出动机：
  - 很多蛋白质具有相似的空间结构，但其序列等同部分小于25%，即远程同源；对于这类蛋白质，难以通过序列比对找出它们之间的关系，需要设计新方法
    - 线索化(Threading)方法，也叫折叠识别(Fold Recognition)技术，**是以结构已知的蛋白质折叠为模板，寻找给定氨基酸序列折叠类型的方法。**

- 线索化是建立序列-结构比对(Sequence-Structure Alignment)过程：
  - 为目标序列U寻找合适的序列模板，这些模板蛋白质序列与目标序列U是远程同源序列，未必具有显著的序列相似性

基本思想和步骤

- 主要思想：
  - 利用氨基酸的结构倾向(比如形成二级结构的倾向/疏水性/极性等)评价一个序列所对应的结构是否能够适配到一个给定的结构环境中



- 线索化方法有5个步骤：
  - 1. 建立核心折叠数据库
  - 2. 确定适合序列-结构比对的三维折叠信息表示方法
  - 3. 定义序列-结构匹配函数，对匹配程度打分
  - 4. 建立序列-结构比对策略
  - 5. 给出评价序列-结构比对显著性的方法

需要解决的问题：

- 一个新测定的蛋白质序列是否能够折叠成已知的模式
- 给定的结构能否在序列数据库中找出所有能折叠成该结构的序列
- 即使能够判断出一个序列与某个结构相匹配，也难以像同源蛋白结构预测一样构建出可靠的结构模型。
- 远缘蛋白序列也可能折叠出类似的空间结构，但并不意味着它们有相似的生物学功能。

3. 从头预测法

- 提出动机：
  - 如果没有已知结构的同源蛋白质、也没有已知结构的远程同源蛋白质，则同源模型化方法和线索化方法均不再适用
  - 需要一种仅仅根据氨基酸序列本身来预测其结构的方法——从头预测法(Ab initio method)

- 基本原理：
  - 假设蛋白质分子取能量最低的空间结构
  - 根据物理/化学原理，通过基于分子力学/分子动力学的理论计算所完成的蛋白质结构预测
    - 考虑疏水作用/氢键/二硫桥/静电作用/范德华力/溶剂作用等

从头预测法

- 基本步骤：
  - 1. 确定蛋白质几何结构的表示方法
  - 2. 定义一个可能空间结构的能量函数
  - 3. 设计有效的结构空间搜索方法

- 能量函数的定义和结构空间搜索方法是从头预测方法的关键

三种方法的比较

- 同源模型法需要得到一个好的序列比对
  - 目标蛋白质序列与模板等同部分超过60%， 则完全可以找到正确的比对；如果相似程度只有20%-25%，则很难找到正确的比对；如果相似度低于20%，无法应用同源模型化方法
    - 同源模型法是预测结果最可靠的方法
- 线索化方法需要找到远程同源蛋白
  - 如果能够找到同一家族的远程同源蛋白质，则可以获得比较好的预测结果；如果找到的模板属于不同的家族，则预测准确性难以保证
- 从头预测方法
  - 需要准确的能量函数和快速搜索策略
  - 通常难以产生准确的预测结构

预测结果的评价

- 基本方法：
  - 取结构已知的蛋白质，对这些蛋白质进行模拟结构预测，将预测结构与真实结构进行比较，分析两者之间的差距
  - 建立公共认可的蛋白质结构测试数据集
    - 比如马里兰生物技术研究中心的CASP (Critical Assessment of protein Structure Prediction)
    - http://predictioncenter.llnl.gov/casp4/

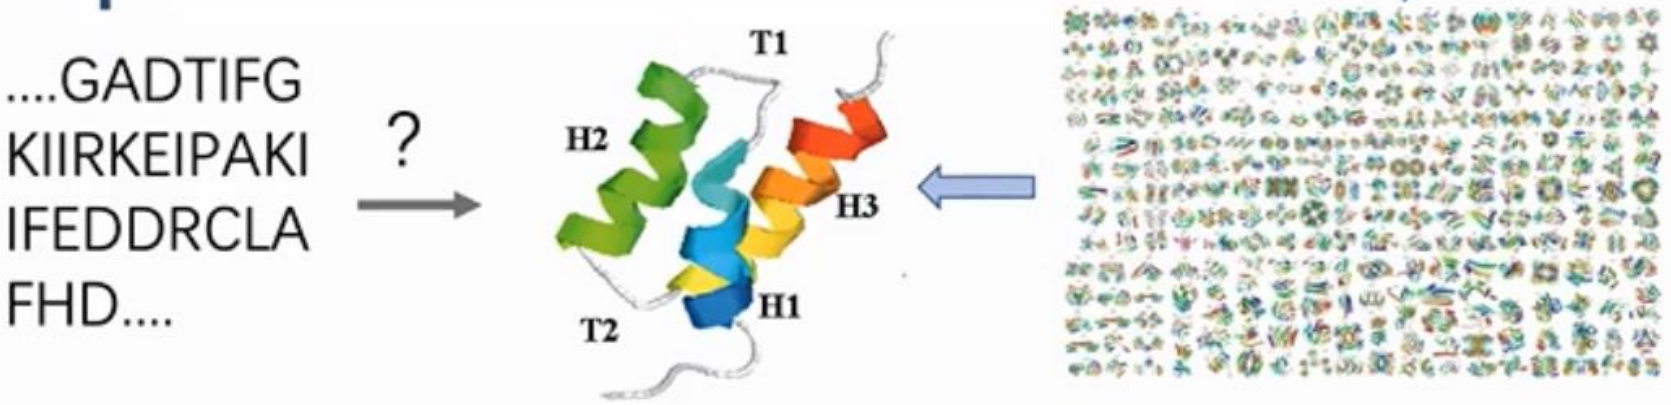
早期工作小结

- 引言
  - 蛋白质
- 蛋白质结构预测
- 蛋白质二级结构预测
  - 经验参数法
  - 相似片断法
  - 同源序列法
- 蛋白质三维空间结构预测
  - 同源模型法
  - 线索化方法
  - 从头计算方法

从头预测的主流方法（2018年前）

60年从序列到结构的奋斗　从头预测：结构碎片+能量函数

减少采样空间：结构碎片；能量函数：统计+经验+物理



模板/结构碎片：ROSETTA，I-TASSER，…

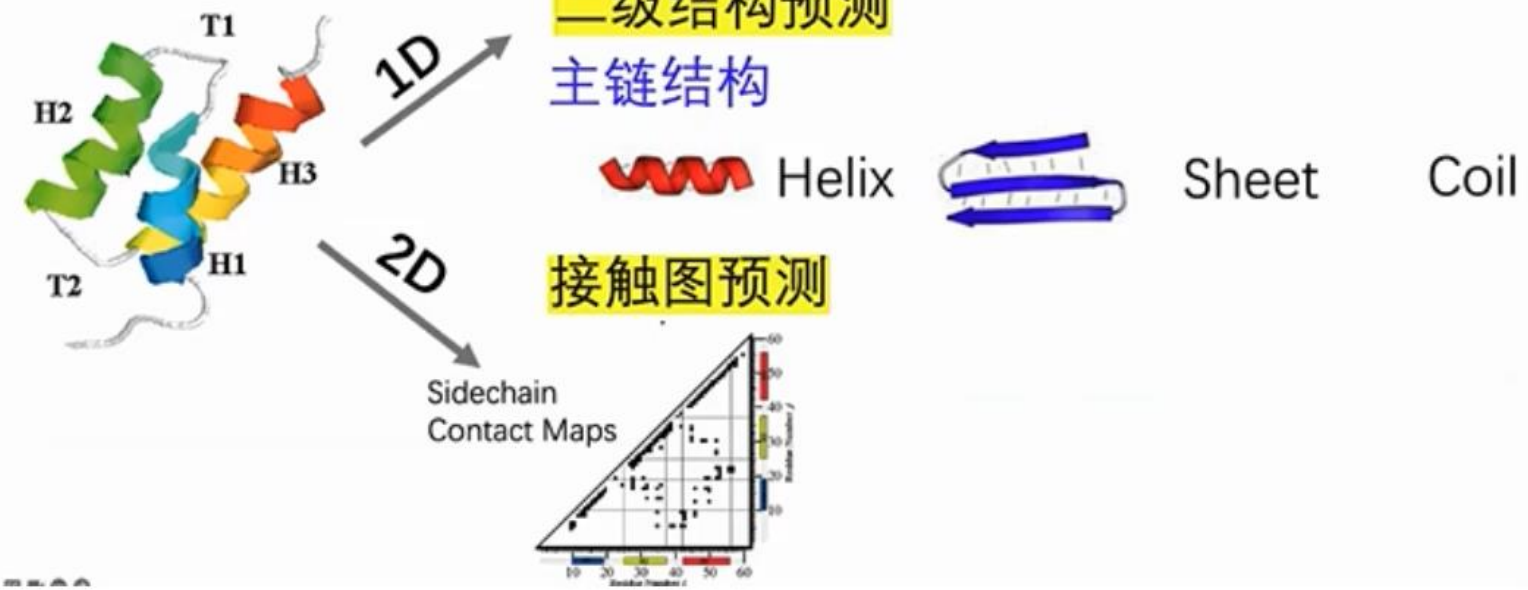
H. Zhou and **Y. Zhou**, "Distance-scaled, finite ideal-gas reference state improves structure-derived potentials of mean force for structure selection and stability prediction, ***Protein Science***, 11 , 2714-2726 (2002). DFIRE 能量函数（>1000引用）

为了解决结构空间过大的问题，结构碎片法成为2018年前的主流方法。这一方法是在找到序列之后，将其分割成多个片段，寻找每个片段相似的已知结构碎片。再利用能量函数将这些碎片组装起来，预测出最终的蛋白质结构。

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

从头预测的主流方法（2018年前）

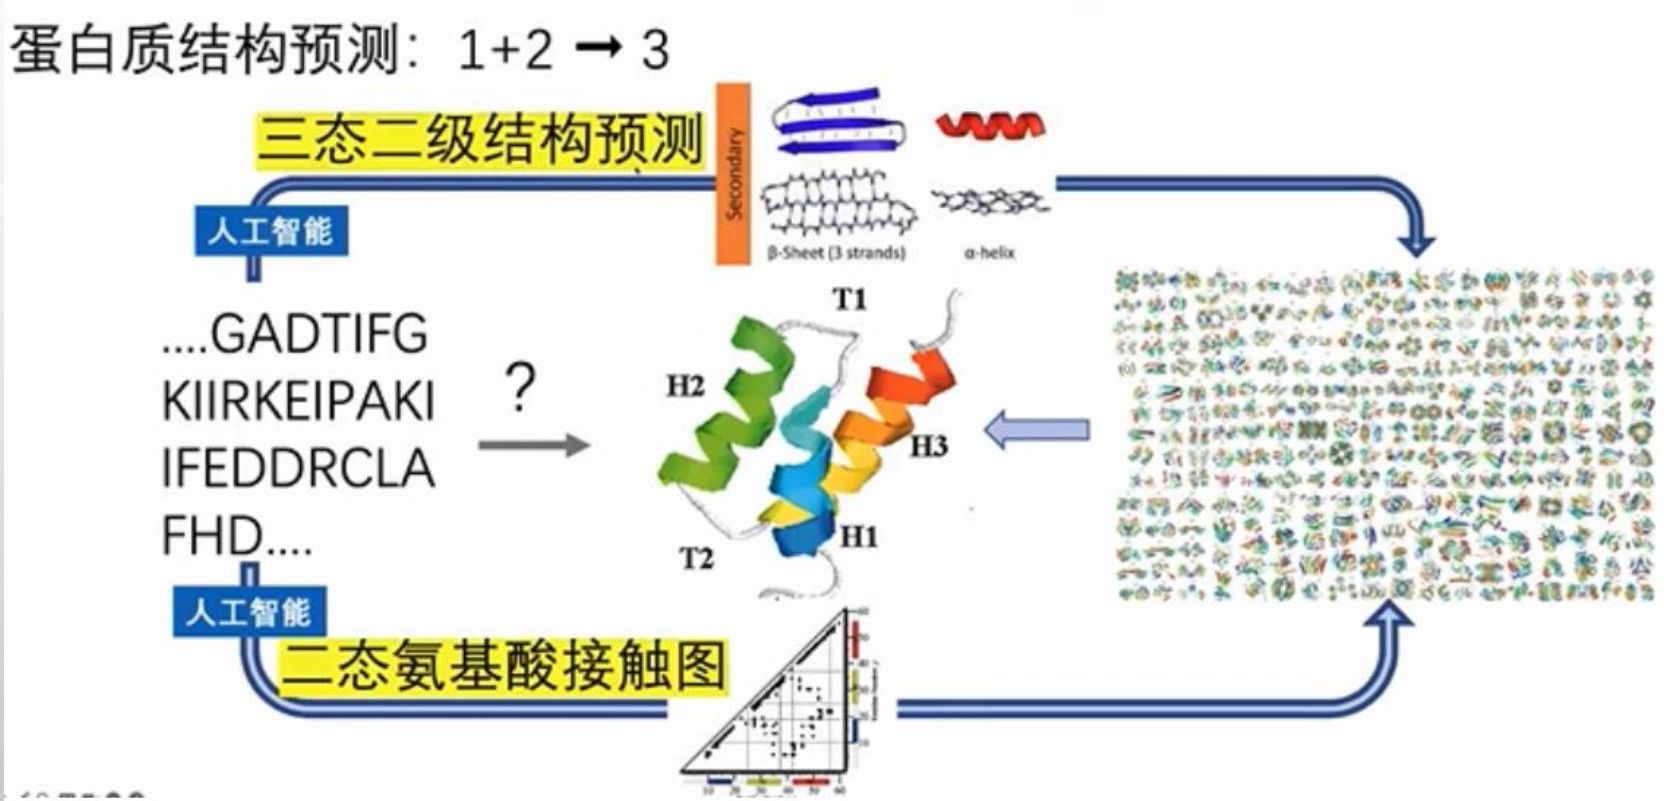
Divide and Conquer，分而治之



将三维结构预测问题分解为一维信息的二级结构预测和二维的接触图预测，变成两个氨基酸之间的距离预测

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

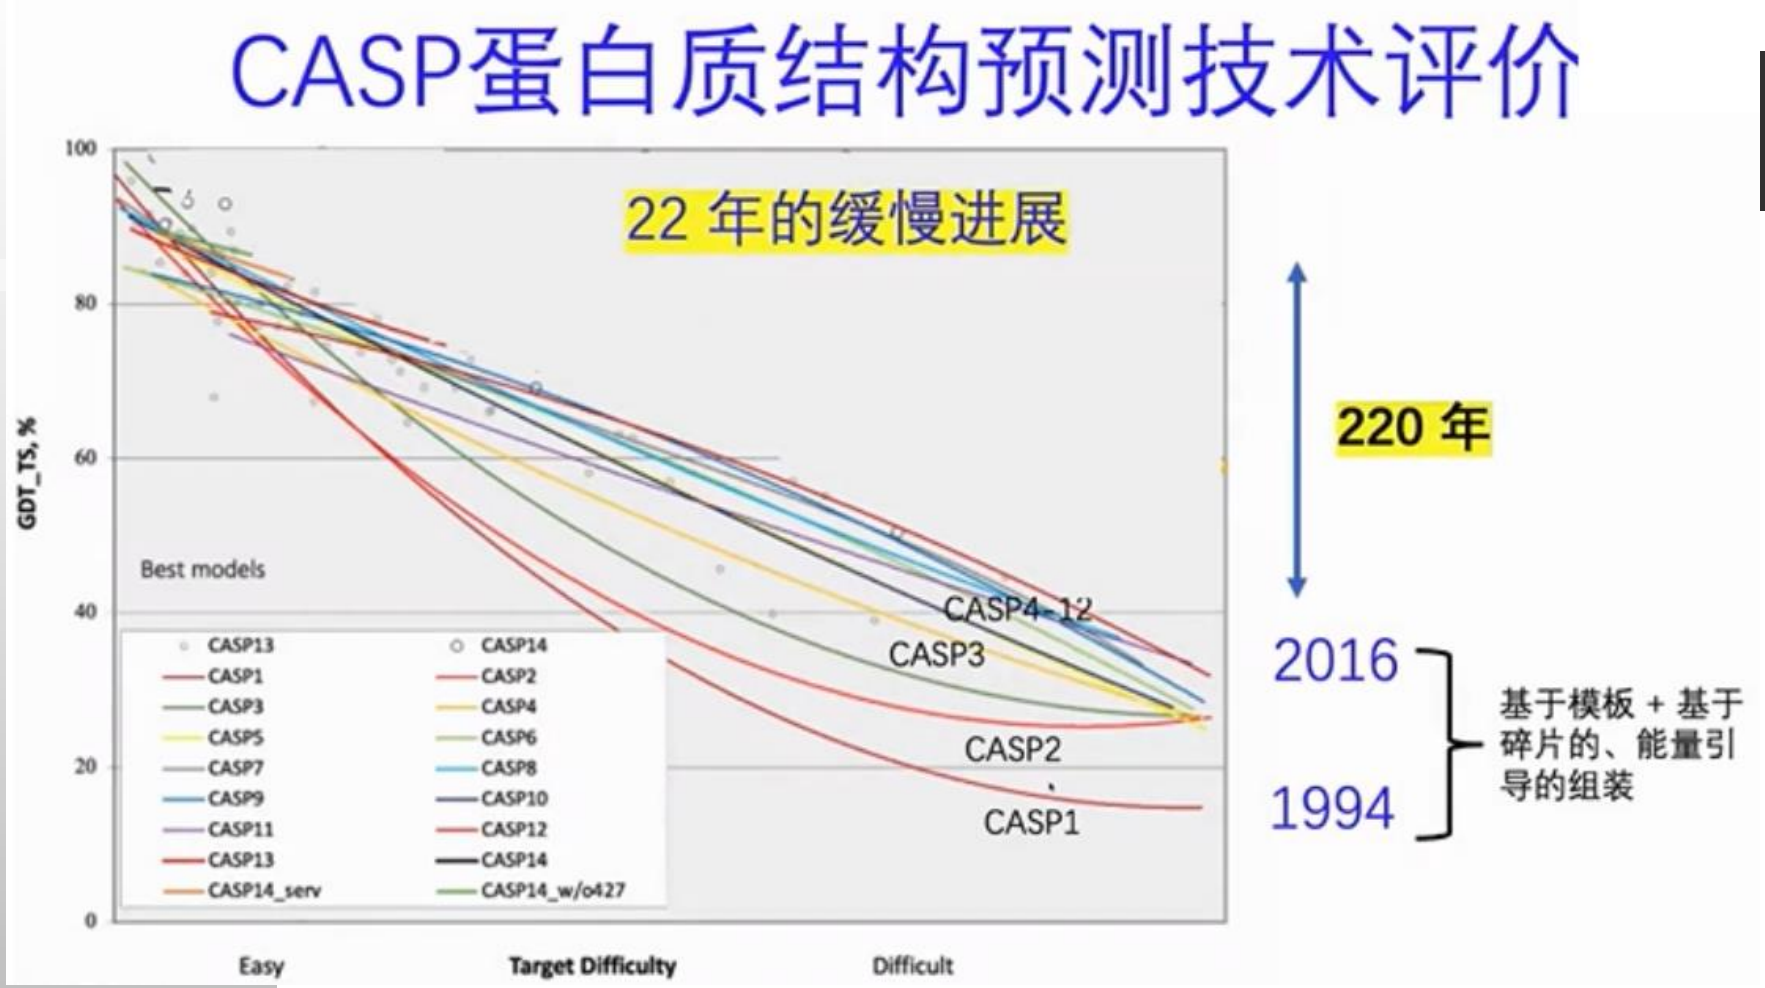
从头预测的主流方法（2018年前）



有了一个序列，我们就可以进行二级结构预测，预测出螺旋、片条或随机线圈等结构，从而找到更匹配的结构碎片。同时，借助人工智能，我们可以预测二态氨基酸接触图。这些接触图可以作为能量函数的约束条件，使它指向更好的三级结构。**这是一种主流的基于结构设计的方法，通过将一级和二级结构信息加上能量函数来实现碎片的组装。**

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

CASP蛋白质结构预测技术评价



在100分满分的CASP评分系统中，85分以上被认为是高精度预测。对于那些难的靶点，其精度一直在缓慢提升。20年来，精度大约提高了20分。

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

Pre-AlphaFold：二面角预测

Theor Chem Acc (2011) 128:3–16
DOI 10.1007/s00214-010-0799-2

FEATURE ARTICLE

Trends in template/fragment-free protein structure prediction

Yaoqi Zhou · Yong Duan · Yuedong Yang ·
Eshel Faraggi · Hongxing Lei

Angle Restraint + DFIRE energy (Top 15)

SPINE-XI（2009）

连续变化

蛋白质序列

....GADTIFG
KIIRKEIPAKI
IFEDDRCLA
FHD....

同源
进化
信息

人工智能

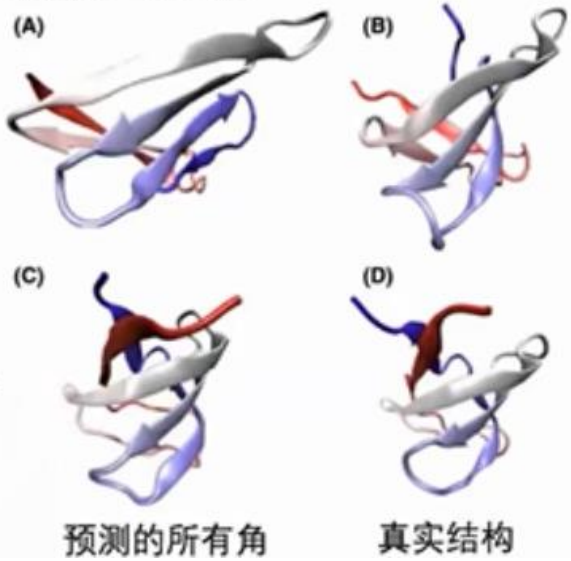
二面角

直接构建
三级结构

特定蛋白质
能量函数

预测的二级结构

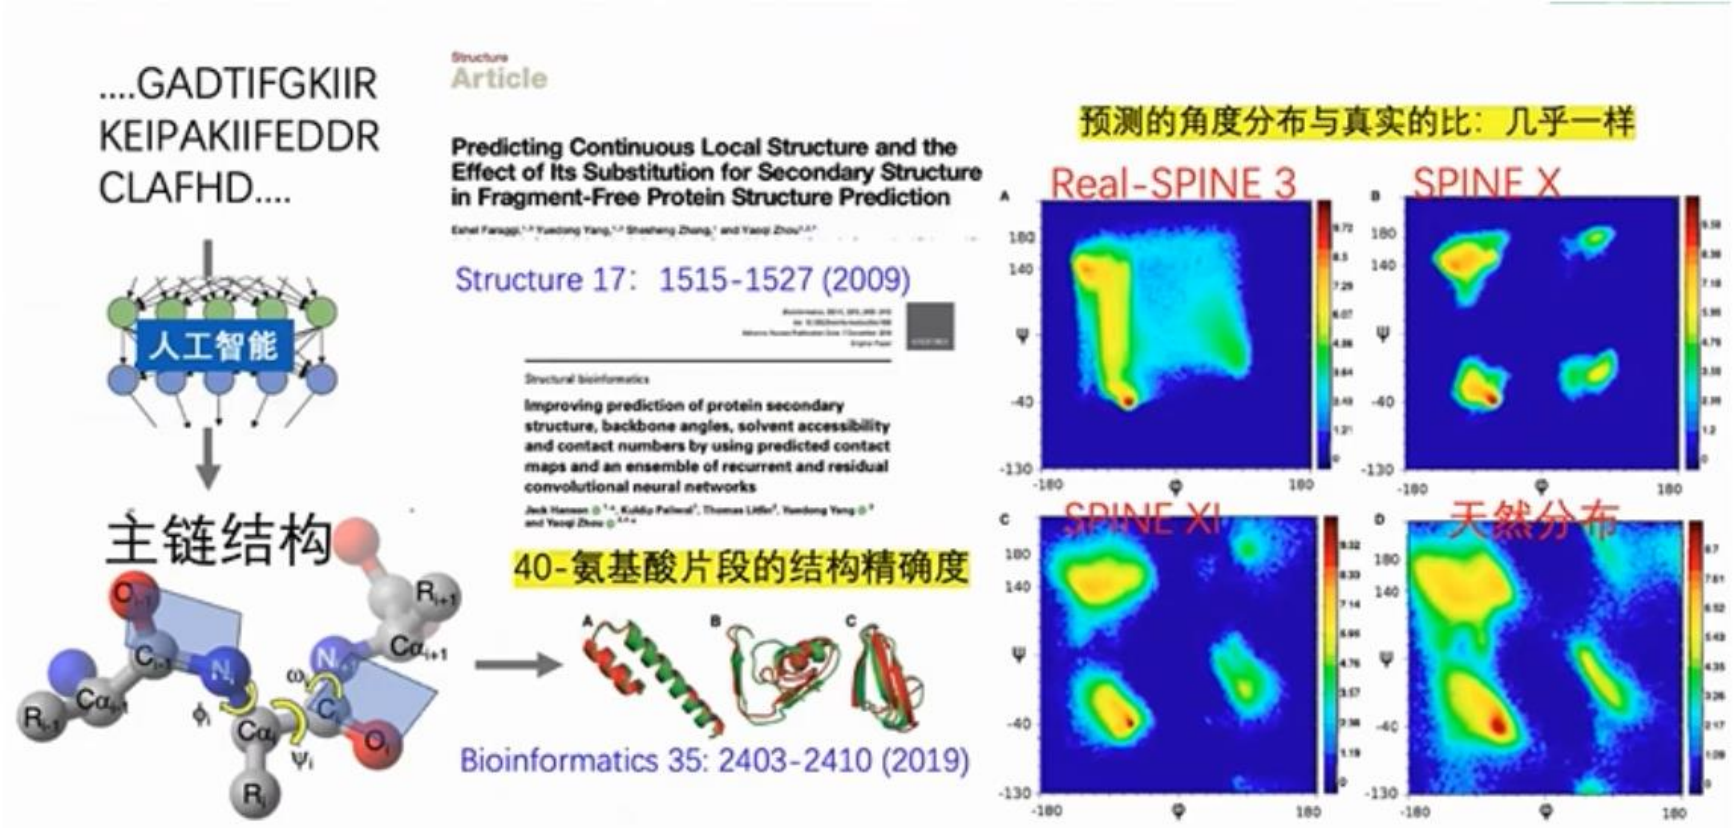
预测的片条
区域二面角



非主流的二面角预测方法不依赖于结构碎片，而是通过序列预测二面角，直接构建主链结构，并利用能量函数和二面角约束来预测三级结构。

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

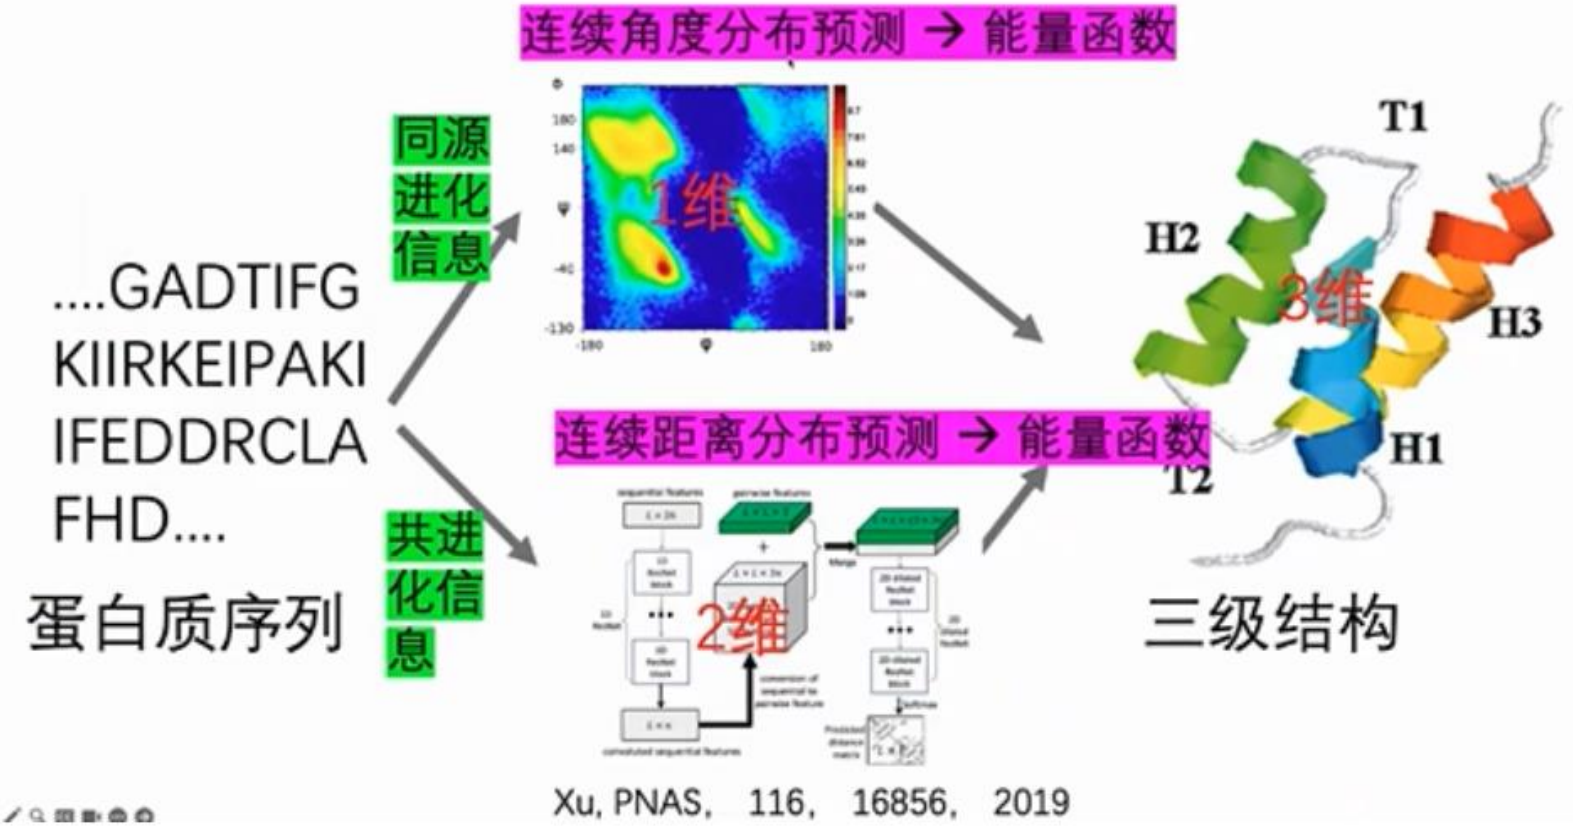
Pre-AlphaFold：二面角预测



随着角度预测的精确度越来越高，碎片预测的精确度也随之提高，因此不再需要依赖碎片进行预测，这就是**无结构碎片的方法**。大约七八年后，许锦波教授在我们工作的基础上，不仅使用角度预测，还加入了距离预测，将问题转化为1+2的问题，结合一维和二维信息，更好地约束三维结构。

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

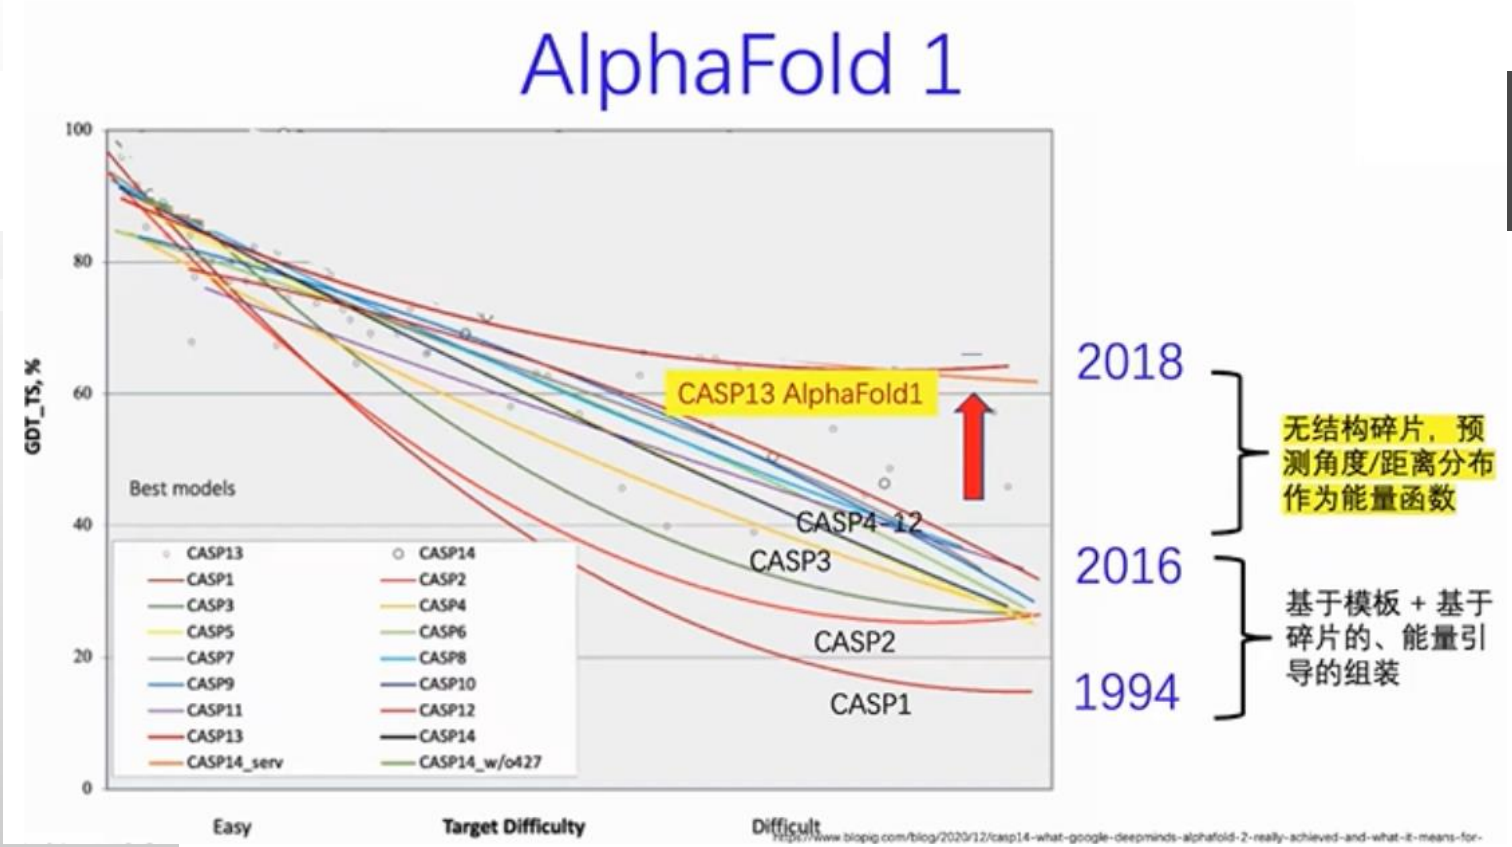
AlphaFold 1



AlphaFold 1就是这种构建方法。**它通过序列预测连续角度分布，转化能量函数，并预测距离，通过距离分布转化能量函数，最终由蛋白质特定的能量函数来推测三维结构。**

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

AlphaFold 1



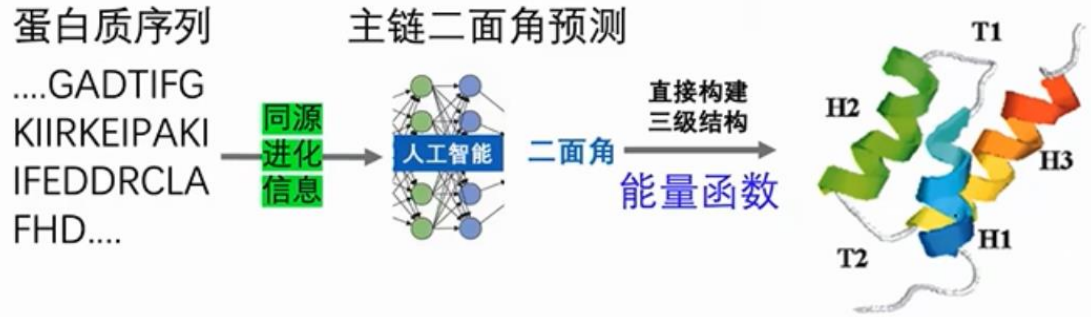
AlphaFold 1成功实现了第一次飞跃。在过去几十年中，由于缺乏创新，一直停滞不前，都是基于碎片的方法。而AlphaFold 1成功地采用了一种非主流的方法，不依赖结构碎片，一下子打开了新局面。碎片方法由于其僵硬性和许多不准确的部分，使得准确组装变得困难，但一旦摆脱了碎片的约束，就实现了一次飞跃。

源自：https://www.jiachengcap.com/blog/20240613
（深圳湾实验室周耀旗）

AlphaFold 1 to AlphaFold 2：端到端预测

连续角预测使端到端预测成为可能

SPINE-XI -2009



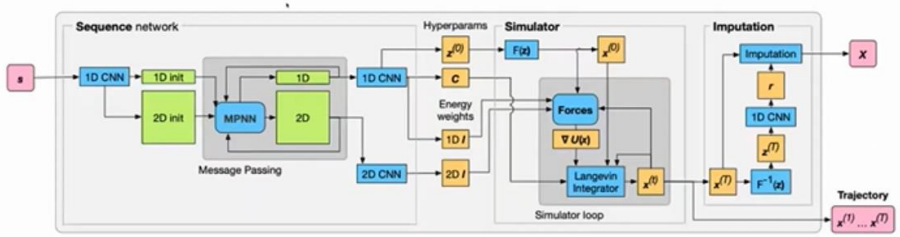
RGN端到端预测

SPINE-XI -2009



1+2 ➡ 3：NEMO端到端预测

NEMO (2019) Marks et al. ICLR, 2019



有2维距离信息的NEMO 超越RGN

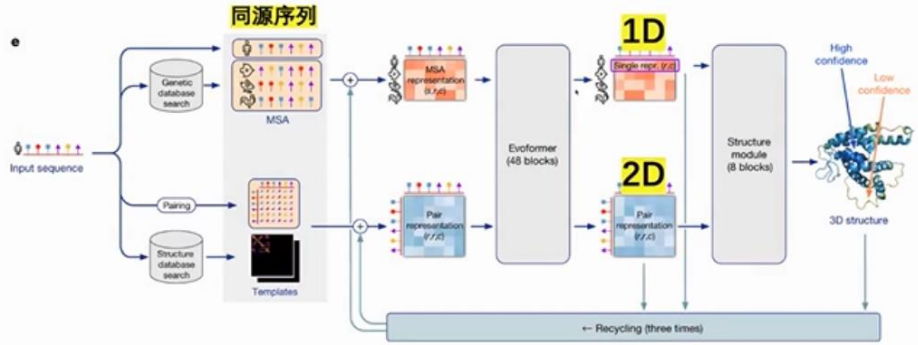
人工智能驱动蛋白质结构预测：AlphaFold 2

完成对所有已知蛋白（>2亿个）的较可靠的结构预测。





AlphaFold 2端到端预测



AlphaFold 2成功的原因

1. 把3级结构简化成 1 + 2的问题；
2. 从分类到连续允许端到端学习
3. 用巨量的参数代替能量函数
4. 直接用比对的同源序列来萃取进化，共进化信息
5. 大序列（25 亿）、结构数据（17 万）、大模型（9300 万个参数）

AlphaFold1

使用的理论和方法：模拟退火、进化共变异、利用残基间距离训练统计势能等。

（1）共进化信息预测残基接触矩阵

（2）残差卷积神经网络。

它通过序列预测连续角度分布，转化能量函数，并预测距离，通过距离分布转化能量函数，最终由蛋白质特定的能量函数来推测三维结构。

AlphaFold2

（1）端到端的预测

（2）无限多的参数替代能量函数

（3）神经网络直接从序列中萃取进化和共进化信息

（4）多序列（25亿），大模型（9300万参数）

AlphaFold3

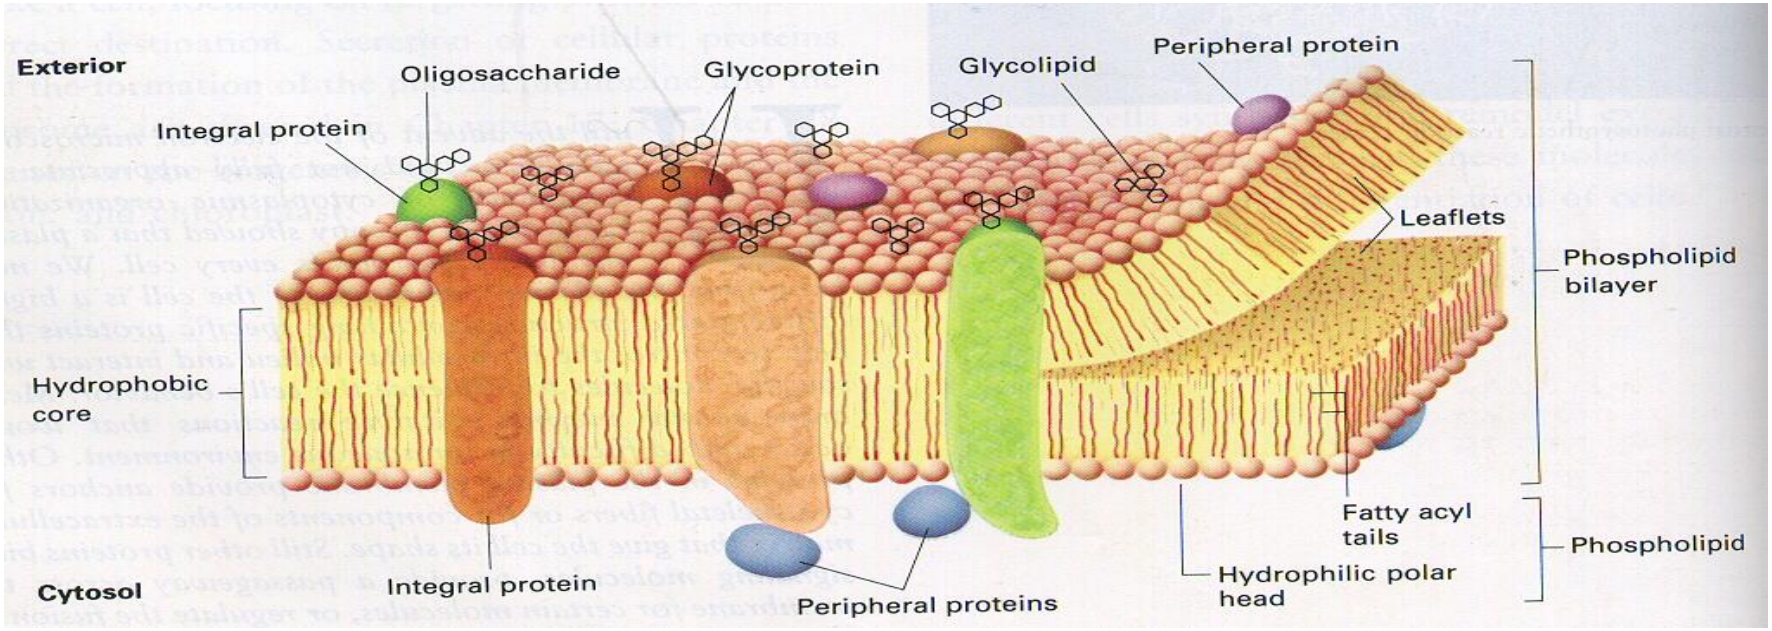
（1）使用了更大的训练数据集，超越了AlphaFold 2所局限的2018年前的数据。

（2）AlphaFold 3不再基于氨基酸类型构建原子，而是直接从原子层面开始构建分子，使其成为一个通用模型，适用于所有分子（小分子，核酸，蛋白质修饰等）。

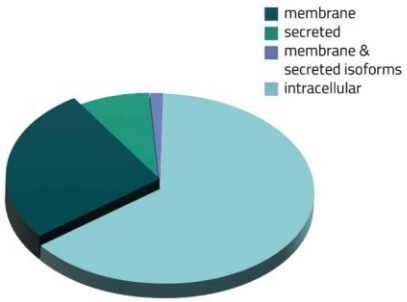
（3）算法改进：引入扩散模块，取代结构模块，更好地与原子构象相搭配，产生更精确的原子构象和结构。

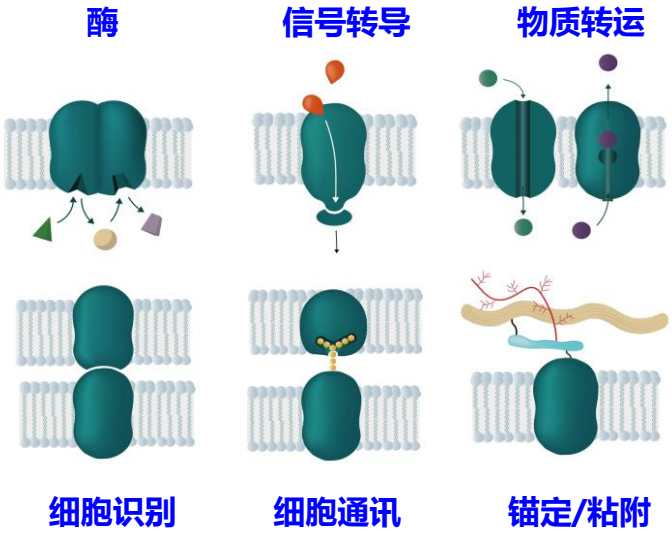
膜蛋白种类

- 膜镶嵌蛋白质
- 膜附着蛋白质



膜蛋白介导了细胞内外物质、能量与信息的交换







1988 光合反应中心

2003 水通道与钾离子通道

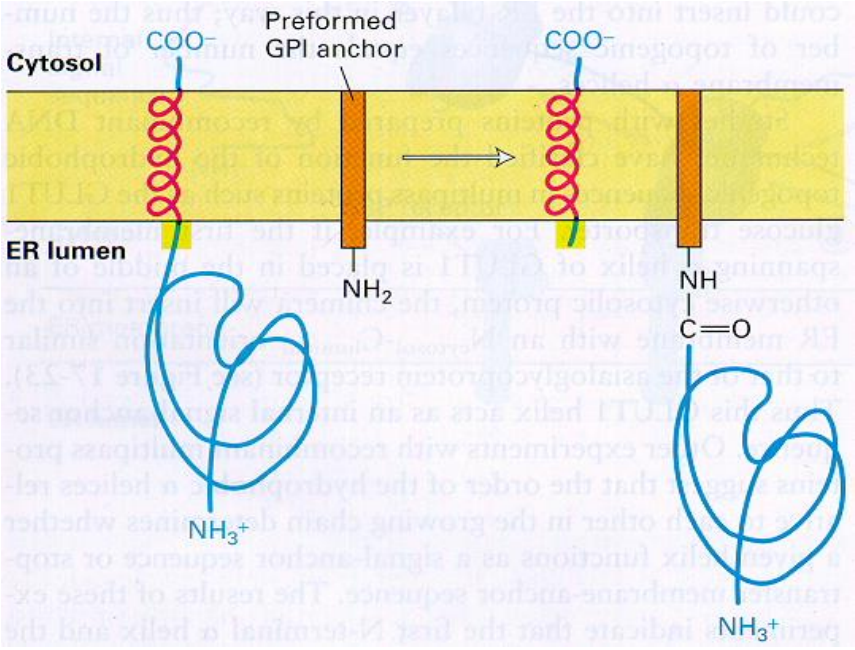
2012 G蛋白偶联受体

2021 温度受体与压力受体

- 膜蛋白基因占人类基因组的约1/4
- 膜蛋白功能具有多样性
- 膜蛋白在生命活动中起到重要作用

- 膜蛋白的跨膜区一般形成α - 螺旋
- 膜附着蛋白质的形成
  - 形成膜镶嵌蛋白质
  - 内质网腔中的部分蛋白被剪切
  - 与膜脂分子（如GPI）连接
  - 跨膜区滞留在脂质双层中

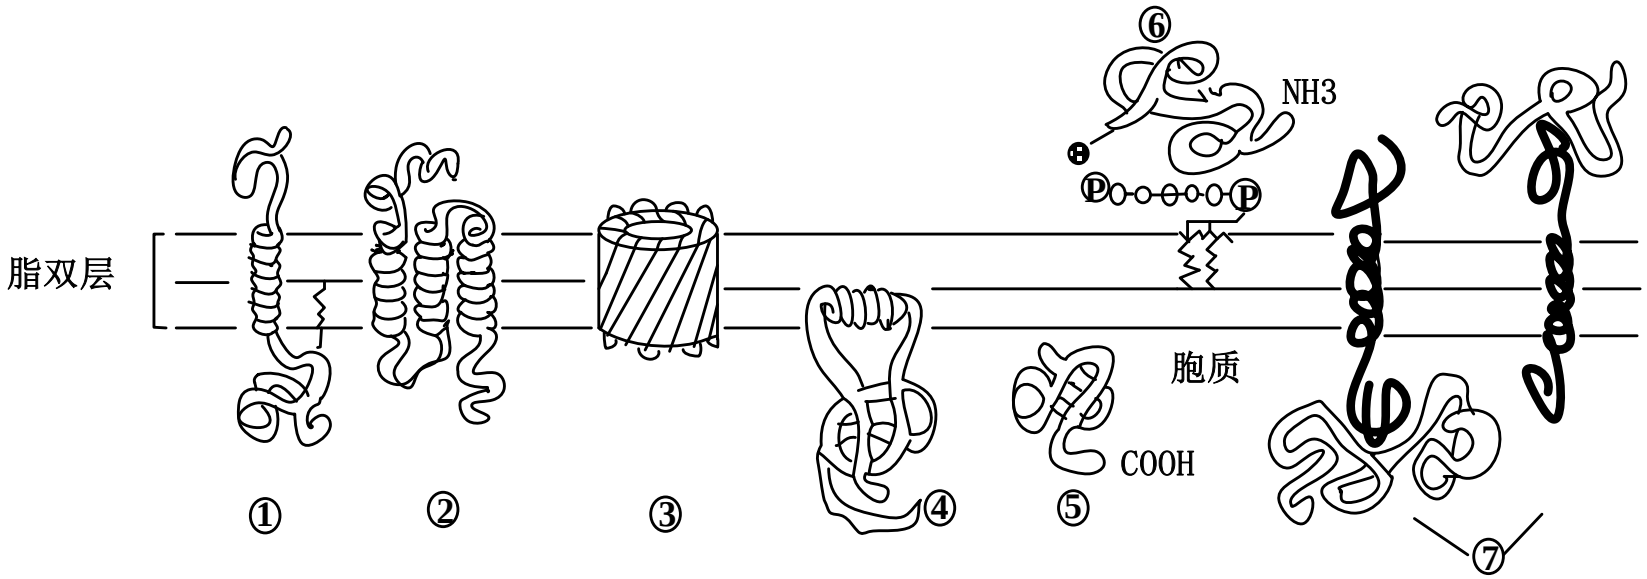
1. 预测蛋白质的跨膜区
2. 分析膜附着蛋白质的GPI剪切位点



蛋白质跨膜区预测

- **膜蛋白跨膜区结构特点**
  - 膜蛋白跨膜区氨基酸具有极强疏水性
  - 跨膜区的二级结构一般为α螺旋和β筒状结构

20-30个连续高度疏水氨基酸可以α螺旋形式穿越脂双层；β筒跨膜区的氨基酸只有20个左右。



跨膜蛋白序列“边界”原则

- **胞外末端**：Asp（天冬氨酸）、Ser（丝氨酸）和Pro（脯氨酸）
- **胞外-内分界区**：Trp（色氨酸）
- **跨膜区**：Leu（亮氨酸）、Ile（异亮氨酸）、Val（缬氨酸）、Met（甲硫氨酸）、Phe（苯丙氨酸）、Trp（色氨酸）、Cys（半胱氨酸）、Ala（丙氨酸）、Pro（脯氨酸）和Gly（甘氨酸）
- **胞内-外分界区**：Tyr（络氨酸）、Trp（色氨酸）和Phe（苯丙氨酸）
- **胞内末端**：Lys（赖氨酸）和Arg（精氨酸）

- 正电荷居内规则：带正电荷的氨基酸主要分布在紧靠膜内连接跨膜区的环上。

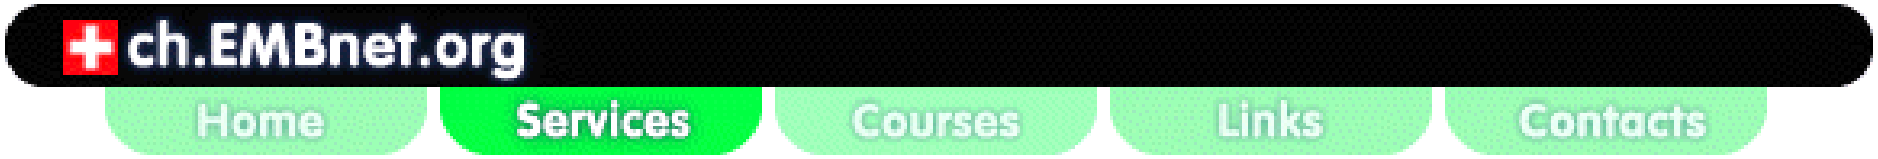
常用蛋白质跨膜区域分析工具

工具	网站	备注
DAS	http://www.sbc.su.se/~miklos/DAS/	用Dense Alignment Surface（DAS）算法来预测无同源家族的蛋白跨膜区
HMMTOP	http://www.enzim.hu/hmmtop/	由Enzymology研究所开发的蛋白质跨膜区和拓扑结构预测程序
SOSUI	http://bp.nuap.nagoya-u.ac.jp/sosui/	由Nagoya大学开发一个具有图形显示跨膜区的程序
TMAP	http://bioinfo.limbo.ifm.liu.se/tmap/	基于多序列比对来预测跨膜区的程序
TMHMM	http://www.cbs.dtu.dk/services/TMHMM-2.0	基于HMM方法的蛋白质跨膜区预测工具
TMpred	http://www.ch.embnet.org/software/TMPRED_form.html	基于对TMbase数据库的统计分析来预测蛋白质跨膜区和跨膜方向
TopPred	http://bioweb.pasteur.fr/seqanal/interfaces/toppred.html	是一个位于法国的蛋白质拓扑结构预测程序

http://www.ch.embnet.org/software/TMPRED_form.html

依靠跨膜蛋白数据库TMbase

预测跨膜区和跨膜方向



TMpred - Prediction of Transmembrane Regions and Orientation

The TMpred program makes a prediction of membrane-spanning regions and their orientation. The algorithm is based on the statistical analysis of TMbase, a database of naturally occuring transmembrane proteins. The prediction is made using a combination of several weight-matrices for scoring.

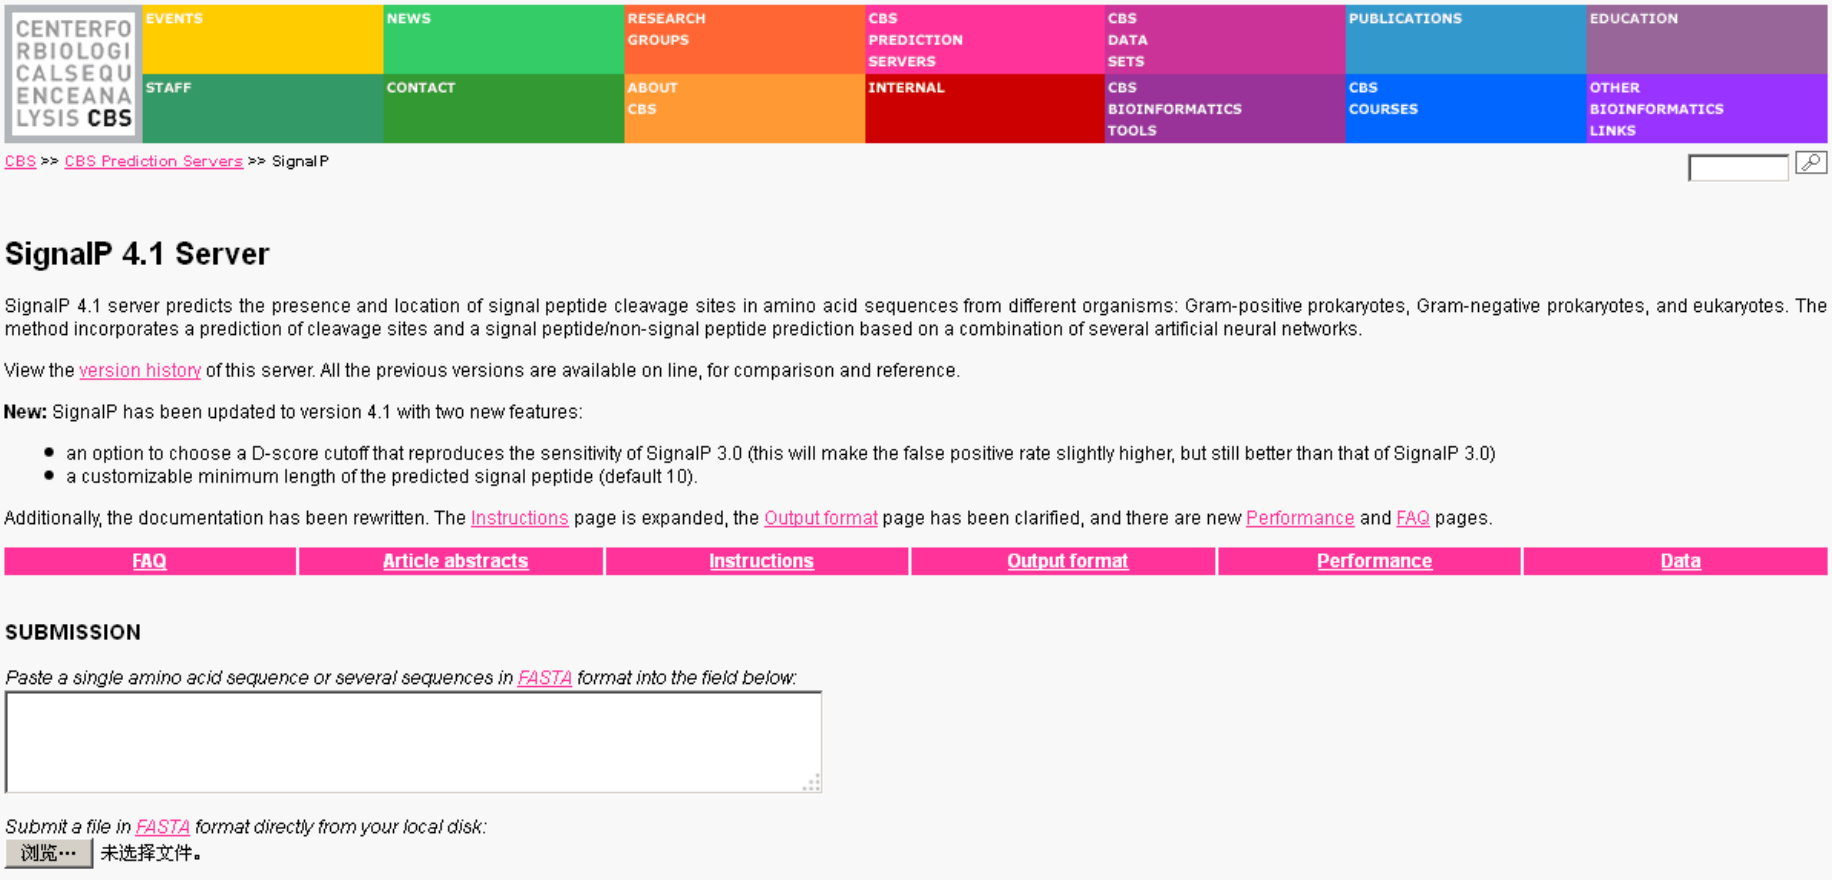
K. Hofmann & W. Stoffel (1993)
TMbase - A database of membrane spanning proteins segments
Biol. Chem. Hoppe-Seyler **374**,166

信号肽预测

- 分泌蛋白和膜蛋白新生肽链N端的一段20～30氨基酸残基组成的肽段。将分泌蛋白引导进入内质网，同时这个肽段被切除。现这一概念已扩大到决定新生肽链在细胞中的定位或决定某些氨基酸残基修饰的一些肽段。
- 信号肽可以指导蛋白质的跨膜转移。
- 预测给定的氨基酸序列中是否存在潜在的信号肽剪切位点及其所在。
- SignalP
- http://www.cbs.dtu.dk/services/SignalP/

信号肽预测工具：SignalP server

(http://www.cbs.dtu.dk/services/SignalP/)



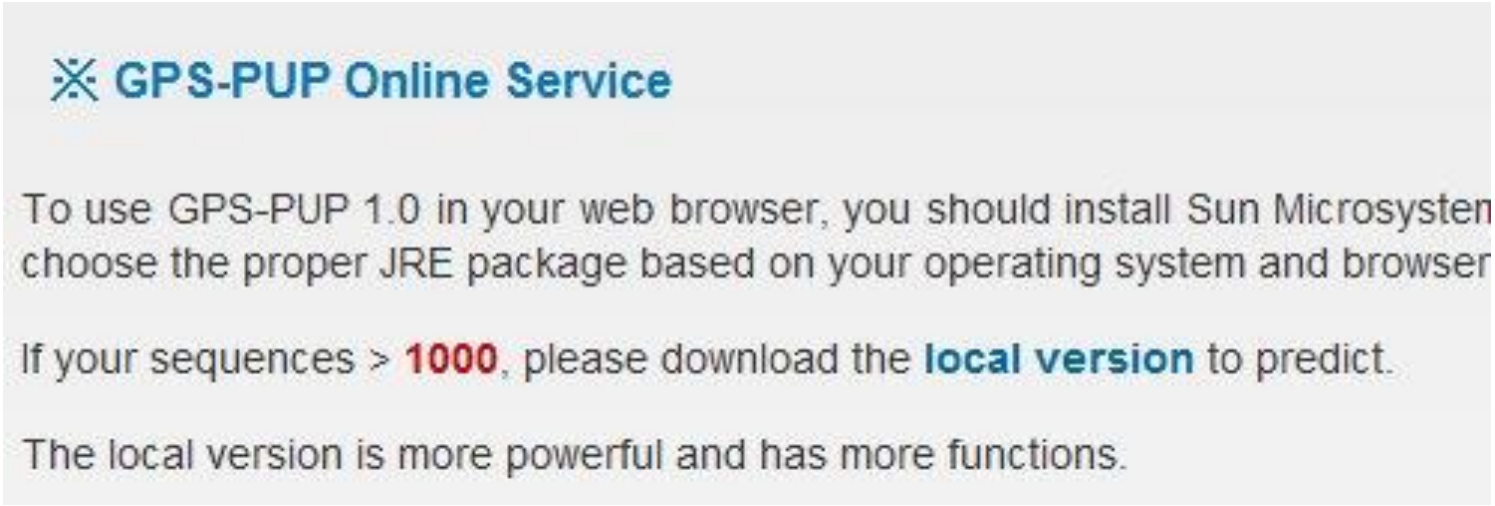
蛋白质的翻译后修饰

几乎所有的蛋白质在合成过程中或者合成后都要经过某些形式的修饰，有的是肽链骨架的剪接，有的是特异氨基酸侧链的化学修饰，这种现象称为翻译后修饰（post-translational modification，PTM）。

- 蛋白组学研究中涉及较多的三种修饰形式：磷酸化、糖基化和泛素化。
- 翻译后修饰明显增加了蛋白质的复杂性，同时也增加了蛋白质结构预测的难度和准确度。

- 糖基化位点预测
- http://www.cbs.dtu.dk/services/NetNGlyc/
- http://www.cbs.dtu.dk/services/NetOGlyc/

- 泛素化位点预测
- **GPS-PUP**
- **http://pup.biocuckoo.org/**



蛋白质复合物结构预测：AlphaFold 2 - 分析蛋白质的相互作用

分析蛋白质的相互作用核心是从分子水平上去研究蛋白质间直接的相互作用。

- 研究方法按研究对象分为两种：研究两个蛋白质间的相互作用和蛋白质复合物的相互作用（组成复合物的多个蛋白质间的相互作用）。
- 按分析的原理分：遗传学方法、生物信息学方法、生物化学方法、物理方法、文库法、酵母双杂交系统、质谱法等。